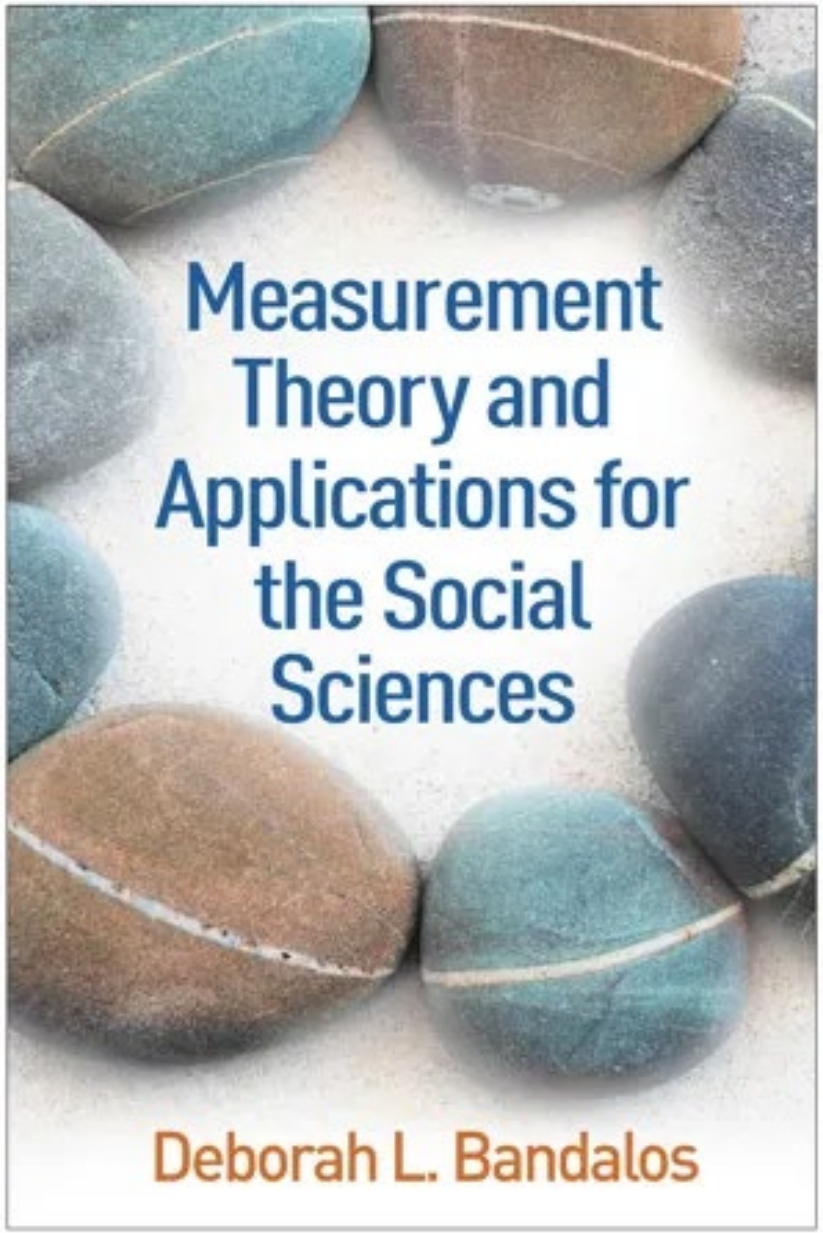
Clase 11
Teoría de respuesta al ítem

Dr. Héctor Nájera
PUED-UNAM



14

Item Response Theory

with Christine E. DeMars

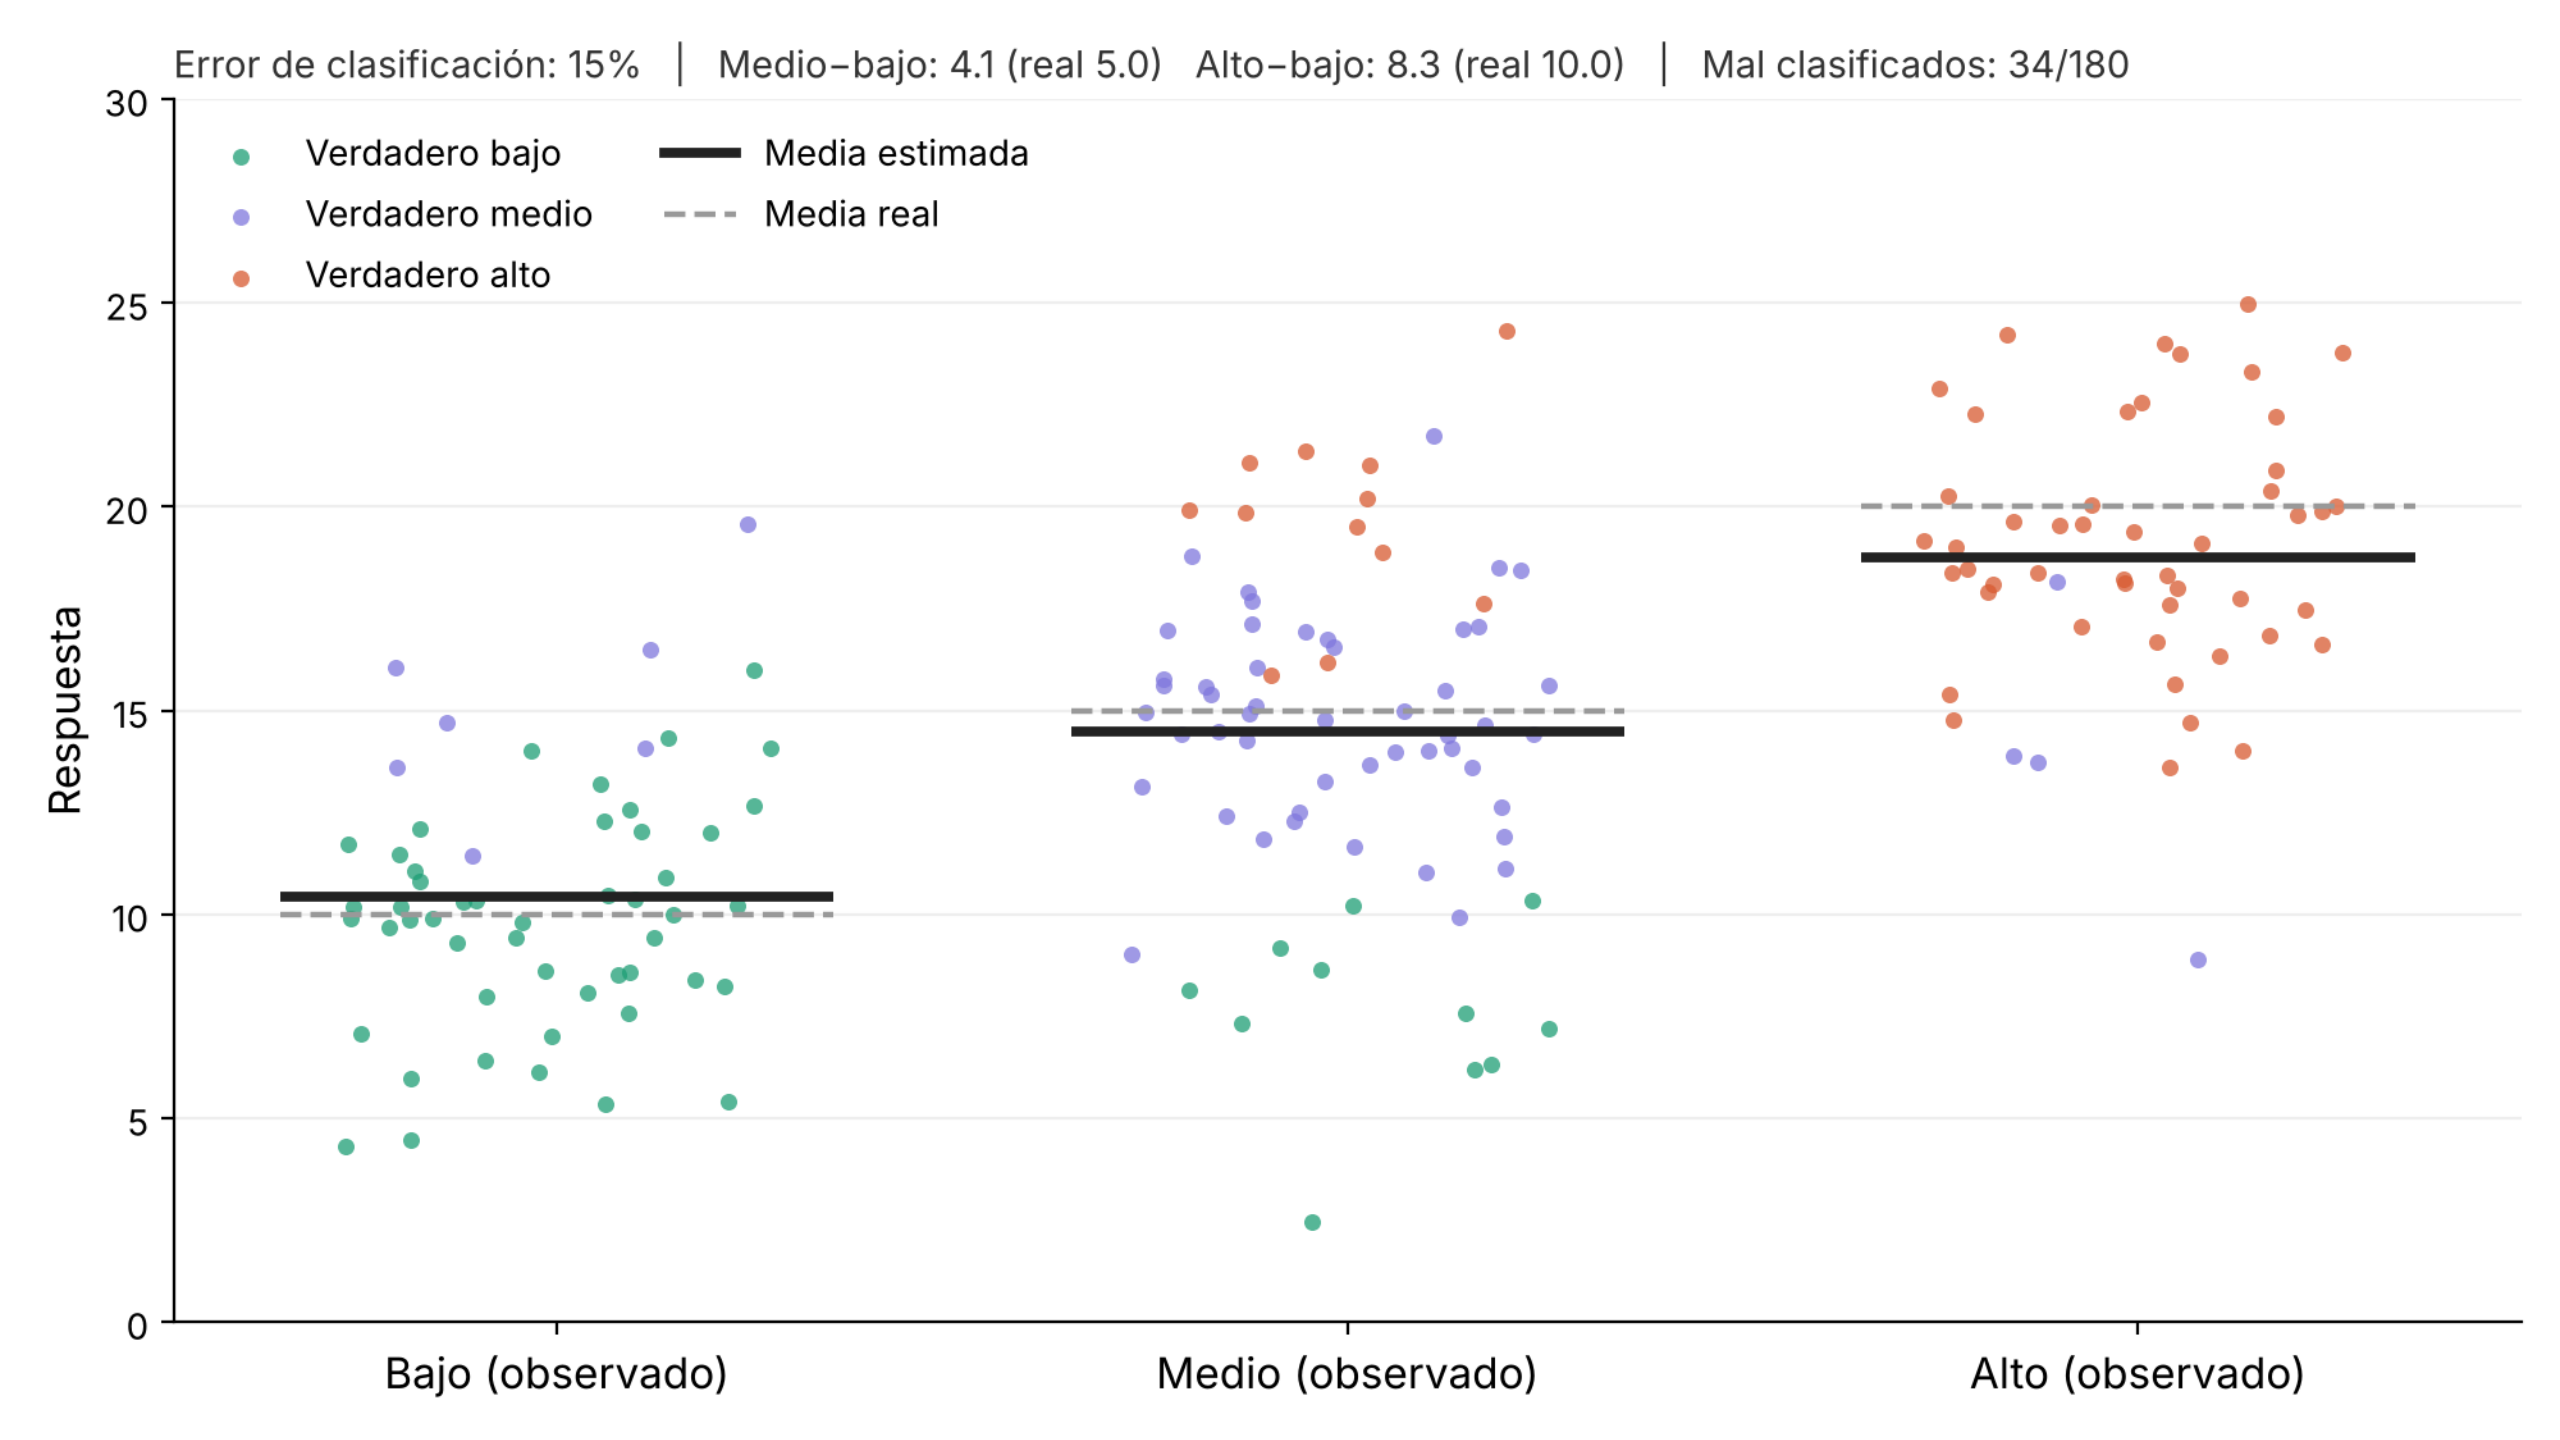
Many of you learned to know and love the CTT model in reading Chapter 7. I can understand why, as the CTT model has much to recommend it. It is a relatively simple model: it is easy to understand, and it does not make too many unreasonable assumptions. However, the CTT model also has some disadvantages, as summarized by Hambleton, Swaminathan, and Rogers (1991, ch. 1). One disadvantage is that in CTT estimates of item difficulty and discrimination are group dependent. As discussed in Chapter 6, the difficulty of a test item under the CTT model is equal to the proportion of examinees in a particular group (representing a particular population) who get the item right. However, if the difficulty had been obtained from a group of examinees with higher ability, the item would appear easier and the item difficulty would be higher (remember that in CTT easier items have higher difficulty values). The same idea holds for discrimination values because these, too, are calculated from data on a particular group of examinees. This makes it quite tricky to compare the difficulty and discrimination values of items that have been administered to different groups, unless we know the groups have the same average ability (and therefore represent the same population).

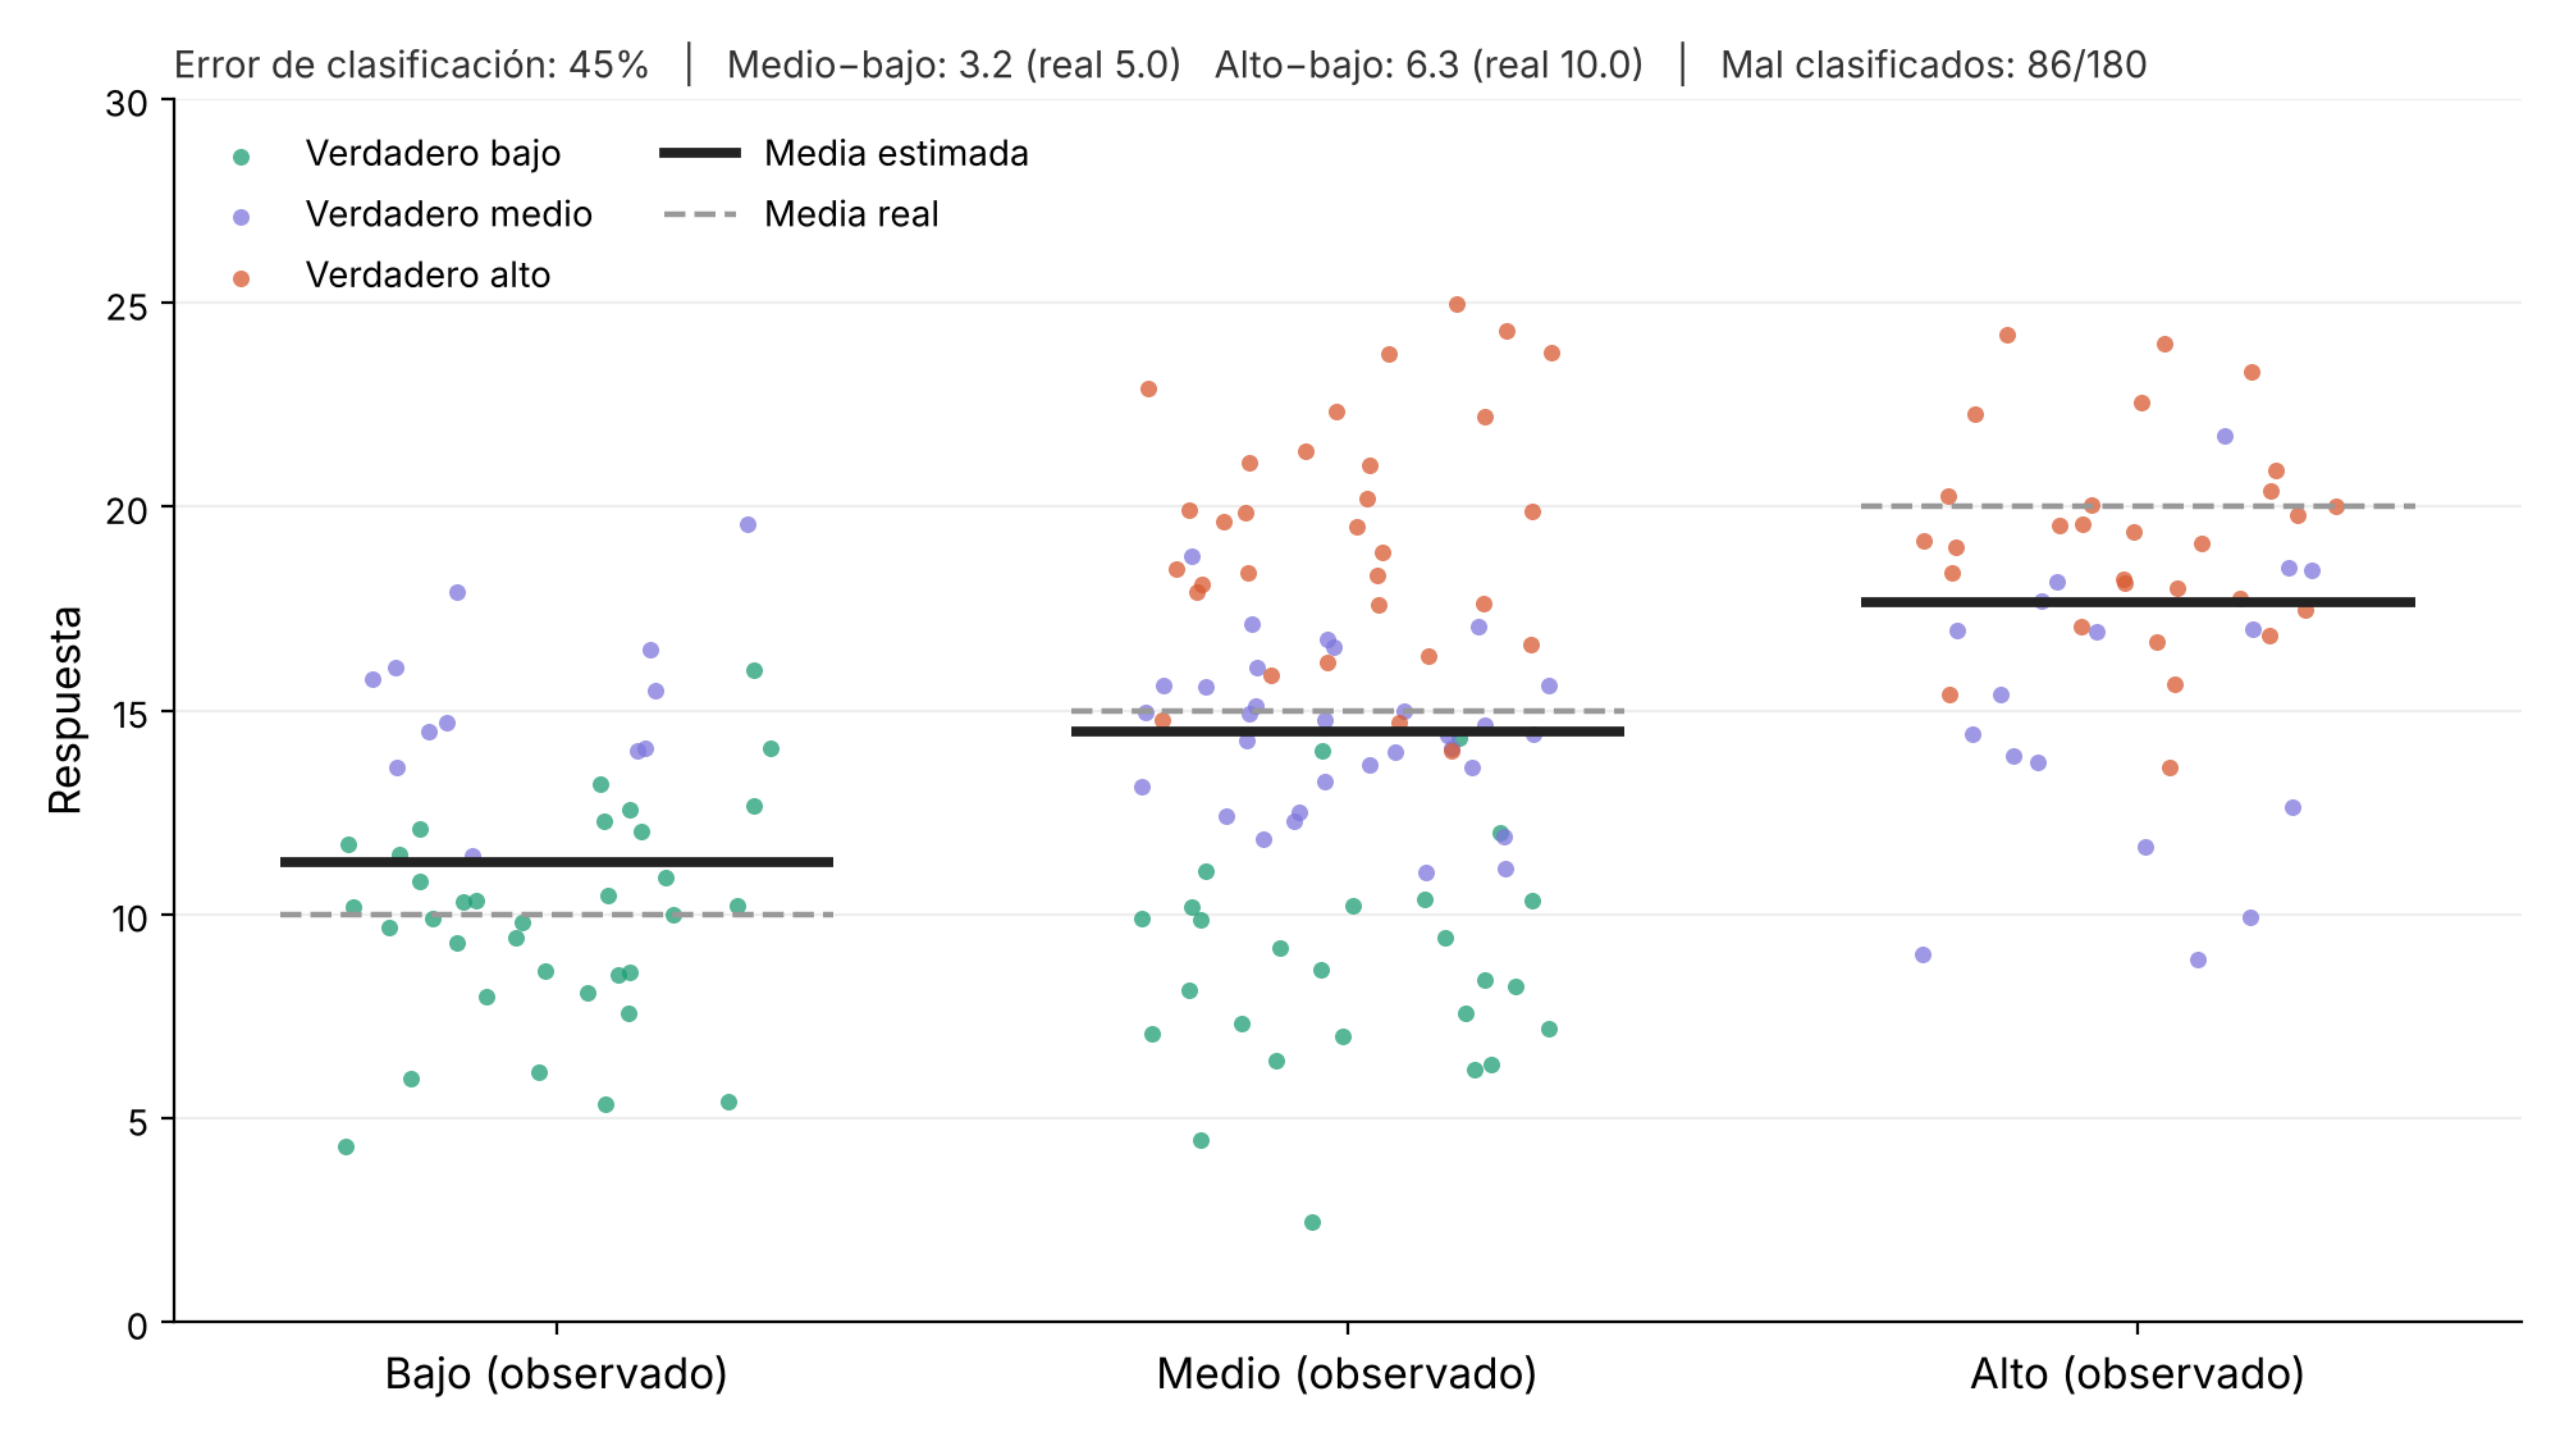
A related problem is that examinees' scores are dependent on the particular test they are administered. This may seem obvious, as a test score in CTT is, of course, a function of examinees' scores on the individual test items. But if easier or harder test items had been used, examinees' scores would change accordingly. And if some examinees took an easier test and some took a harder test, we could not compare their scores, even if the two tests were based on the same material and table of specifications. So, in CTT, estimates of examinee ability are dependent on the item parameters, and estimates of item parameters are dependent on the ability of the group to which the items are administered. The test-dependence of examinees' ability estimates and the ability-dependence of item parameter estimates imply that examinee ability and item parameter values are

Christine E. DeMars, PhD, is Professor in the Department of Graduate Psychology and a senior assessment specialist in the Center for Assessment and Research Studies at James Madison University.

Categorías y estadística

- **¿Cómo podemos abordar el problema de trabajar con categorías en medición y modelación?**
- Si codifico el estado civil como 1 = Soltero/a, 2 = Casado/a, 3 = divorciado/a, 4 = unión libre y:
  - la uso cómo dependiente en una regression lineal ¿Qué estoy suponiendo?
  - la uso cómo dependiente en una regression ordinal ¿Qué estoy suponiendo?
  - la uso cómo dependiente en una regression no proporcional ¿Qué estoy suponiendo?


Error de clasificación: 15% | Medio–bajo: 4.1 (real 5.0) Alto–bajo: 8.3 (real 10.0) | Mal clasificados: 34/180
Verdadero bajo
Verdadero medio
Verdadero alto
Media estimada
Media real
Respuesta
30
25
20
15
10
5
0
Bajo (observado)
Medio (observado)
Alto (observado)


Error de clasificación: 45% | Medio−bajo: 3.2 (real 5.0) Alto−bajo: 6.3 (real 10.0) | Mal clasificados: 86/180
Verdadero bajo
Verdadero medio
Verdadero alto
Media estimada
Media real
Respuesta
30
25
20
15
10
5
0
Bajo (observado)
Medio (observado)
Alto (observado)

Modelos de medición con categorías

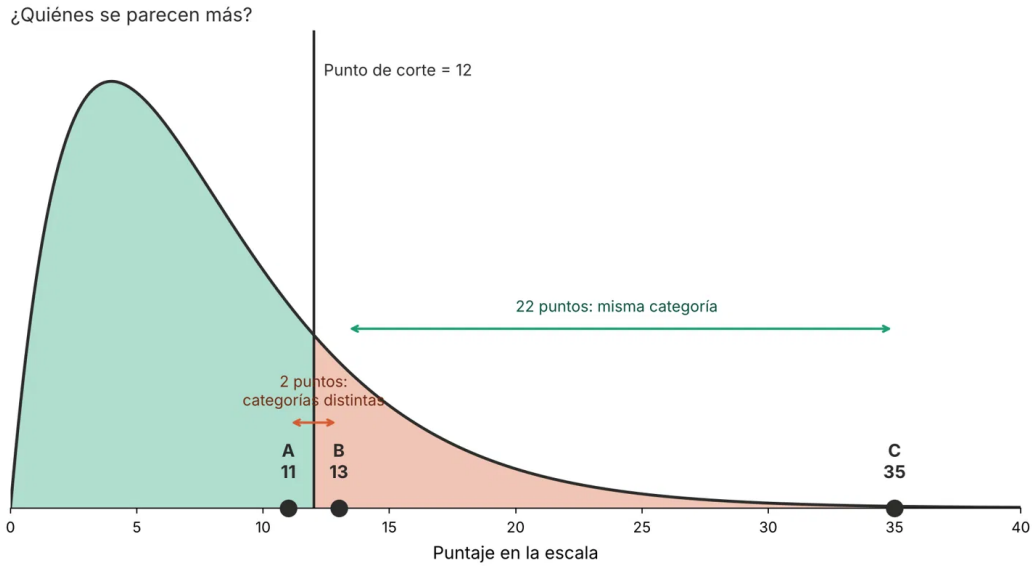
- Sabiduría popular: Si dicotomizas una variable pierdes información.

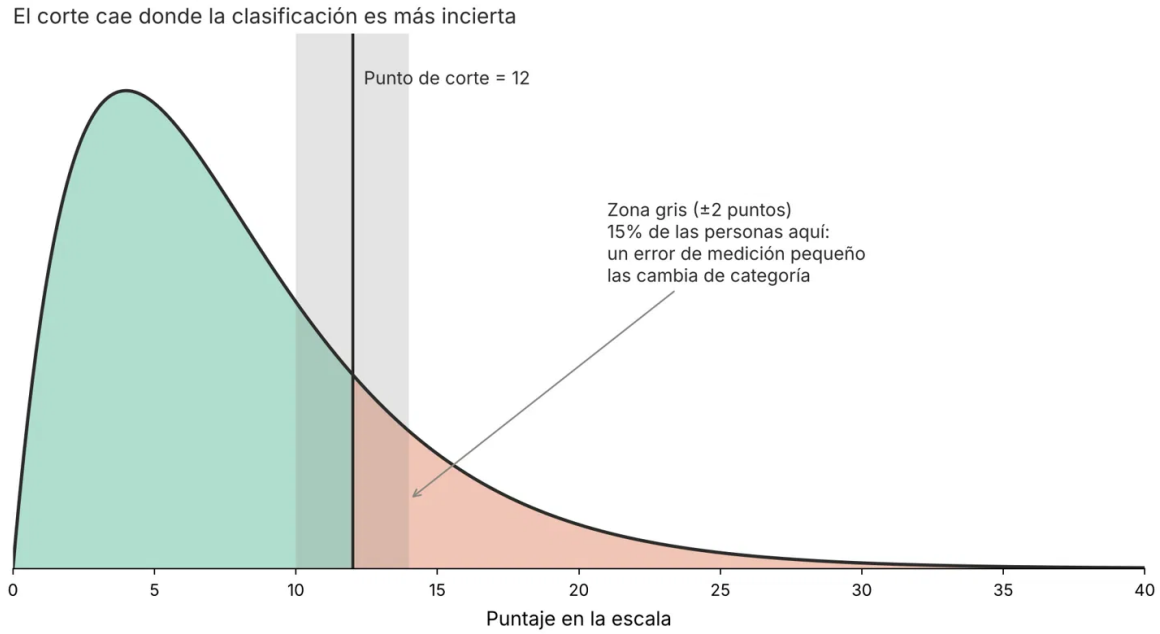
- Sabiduría semi-informada: No hagas regresión lineal cuando la dependiente es categórica

Clasificación

Si un médico clasifica a los pacientes dado un score de adicciones basado en una escala de 25 preguntas en “no adicto/as” y “adicto/as” con un corte en x<z

¿Qué se gana y qué se pierde respecto a usar el score crudo?





Se gana

- Interpretabilidad
- Estandarización
- Proporciones
- Robustez a la forma de la relación (lineal o no)

Se pierde

- Pérdida de variabilidad intra-grupo
- Inferencia sobre las personas cerca del umbral
- Sesgo condicional en el punto de corte
- Manipulación

Medición anidada

- Preguntas categóricas para producir categorías
- Preguntas continuas para producir categorías
- Preguntas continuas para producir scores continuos
- Preguntas categóricas para producir ´scores continuos

Efecto de error de medición-clasificación

¿Qué esperarían que pase con n alto?

Los efectos se atenúan en caso de errores aleatorios de clasificación

¿Qué pasaría si el error afecta la media?

En caso de error sistemático, el modelo no corrige las probabilidades globales medias

¿Qué pasa con las probabilidades?

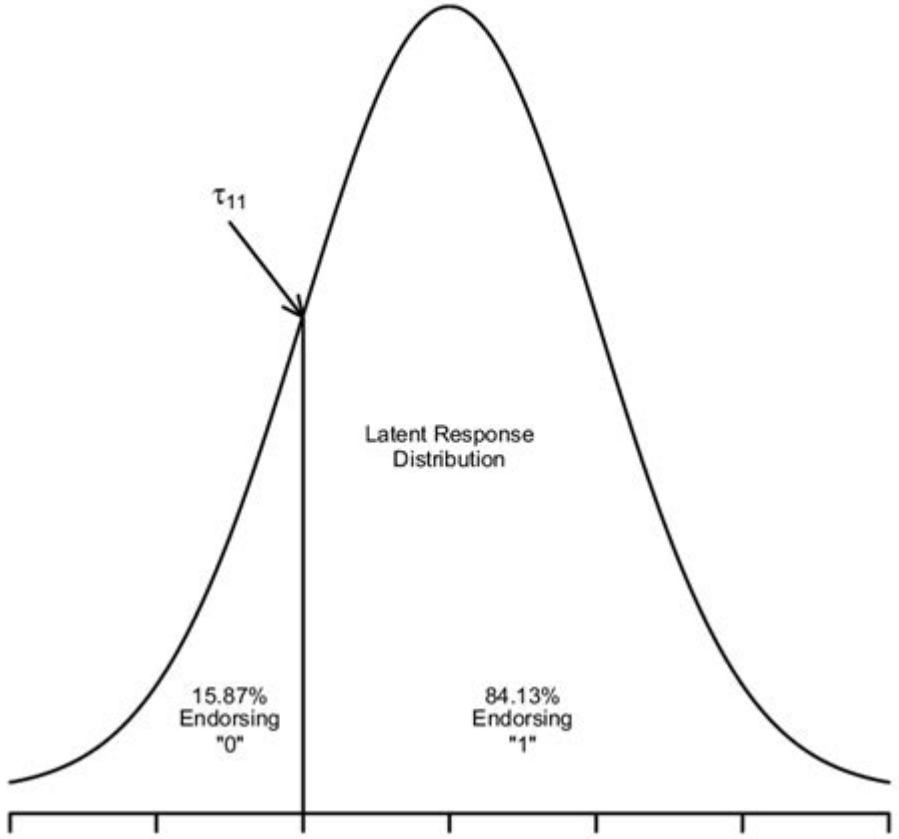
Las probabilidades predichas quedan comprimidas: nunca llegan a 0 ni a 1, porque siempre hay una fracción de falsos positivos y falsos negativos.

Repensando las categorías

Tratamiento clásico. Categorías absolutas/predefinidas: ¿Sexo?, Grupos de edad, estado de nacimiento, religión.

Tratamiento moderno. No todas las categorías son absolutas. Podemos pensar en un continuo, en el que hay un valor crítico que separa a los grupos de interés

¿Qué valor crítico en el continuo produce una buena separación?



Nivel crítico de separación o creación de grupos

Dos modelos de medición complementarios

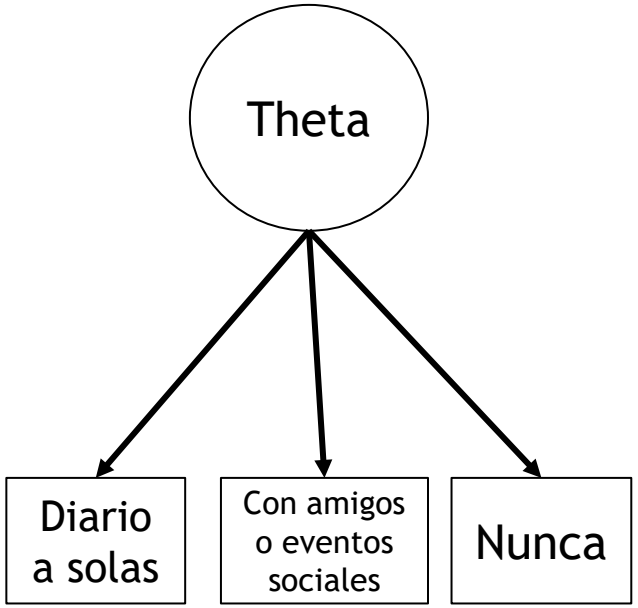
Las respuestas categóricas como manifestaciones de cierto fenómeno (medición)

- Análisis factorial
- Teoría de respuesta al ítem

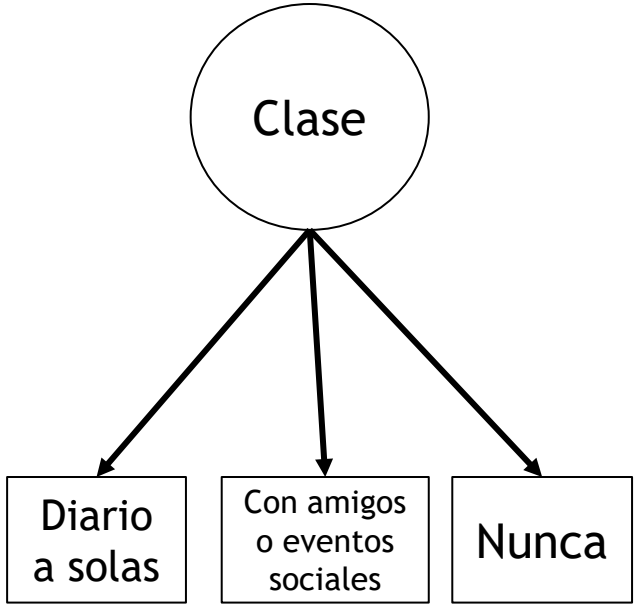
Las respuestas categóricas como manifestaciones de pertenencia a cierto grupo (clasificación)

- Análisis de mezclas
- Clases latentes

Dos modelos de medición complementarios



Buena clasificación requiere buena medición



Cambios en el nivel subyacente de alcoholismo explica la variabilidad de las respuestas

Pertenencia al grupo de alcohólicos explica la probabilidad de respuesta

Estadísticas sociales y variables categóricas



1	0	1	0	1	1	1	1
2	1	0	1	0	0	0	1
3	0	1	1	1	1	0	0
4	0	0	0	0	0	1	1
5	0	0	1	0	0	1	0
6	1	1	1	1	0	1	0
7	0	0	0	0	0	1	0
8	1	1	1	1	0	0	1
9	0	0	0	0	0	0	0
10	1	0	0	1	0	0	0
11	0	0	0	1	1	0	0
12	1	1	0	0	1	1	1
13	1	0	0	1	0	1	1
14	1	0	0	1	0	1	1
15	1	0	1	1	0	1	0
16	0	1	0	1	0	0	1
17	1	0	1	1	1	0	1
18	1	0	0	0	0	1	0
19	1	1	0	1	0	0	0

Variables categóricas

¿Por qué observamos patrones de respuesta: 1 (Sí) ; 0 (No)?

Item response modelling (Edinburgh)

PSYCHOMETRIKA—VOL. 7, NO. 1
FEBRUARY, 1942

ITEM SELECTION BY THE CONSTANT PROCESS*

GEORGE A. FERGUSON
DEPARTMENT OF EDUCATIONAL RESEARCH, UNIVERSITY OF TORONTO

This paper relates the constant process used in psychophysics to the problem of item selection. Each test item may be described in terms of a limen, which is an index of the point at which an item discriminates, and the standard deviation of the limen, which is an index of the
be related n
scription of
terms of a l

PSYCHOMETRIKA—VOL. 9, NO. 1
MARCH, 1944

THE APPLICATION OF PROBIT ANALYSIS TO THE RESULTS OF MENTAL TESTS

D. J. FINNEY
ROTHAMSTED EXPERIMENTAL STATION

The application of the Müller-Urban constant process to item selection, as considered in a recent paper in this journal, is shown to
use for the analysis

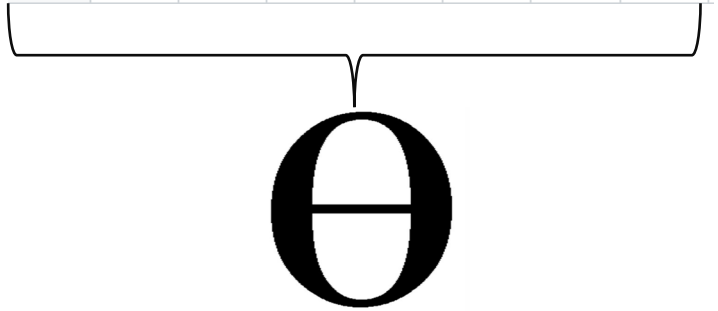
XXIII.—**On Problems connected with Item Selection and Test Construction.** By **D. N. Lawley,** Moray House, University of Edinburgh. *Communicated by* Professor GODFREY H. THOMSON.

(MS. received December 16, 1942. Read March 1, 1943.)

1. IN constructing tests designed to measure mental ability it has been a common practice to use a fairly large number of questions or items each

Variables latentes y probabilidad de respuesta

1	0	1	0	1	1	1	1
2	1	0	1	0	0	0	1
3	0	1	1	1	1	0	0
4	0	0	0	0	0	1	1
5	0	0	1	0	0	1	0
6	1	1	1	1	0	1	0
7	0	0	0	0	0	1	0
8	1	1	1	1	0	0	1
9	0	0	0	0	0	0	0
10	1	0	0	1	0	0	0
11	0	0	0	1	1	0	0
12	1	1	0	0	1	1	1
13	1	0	0	1	0	1	1
14	1	0	0	1	0	1	1
15	1	0	1	1	0	1	0
16	0	1	0	1	0	0	1
17	1	0	1	1	1	0	1
18	1	0	0	0	0	1	0
19	1	1	0	1	0	0	0

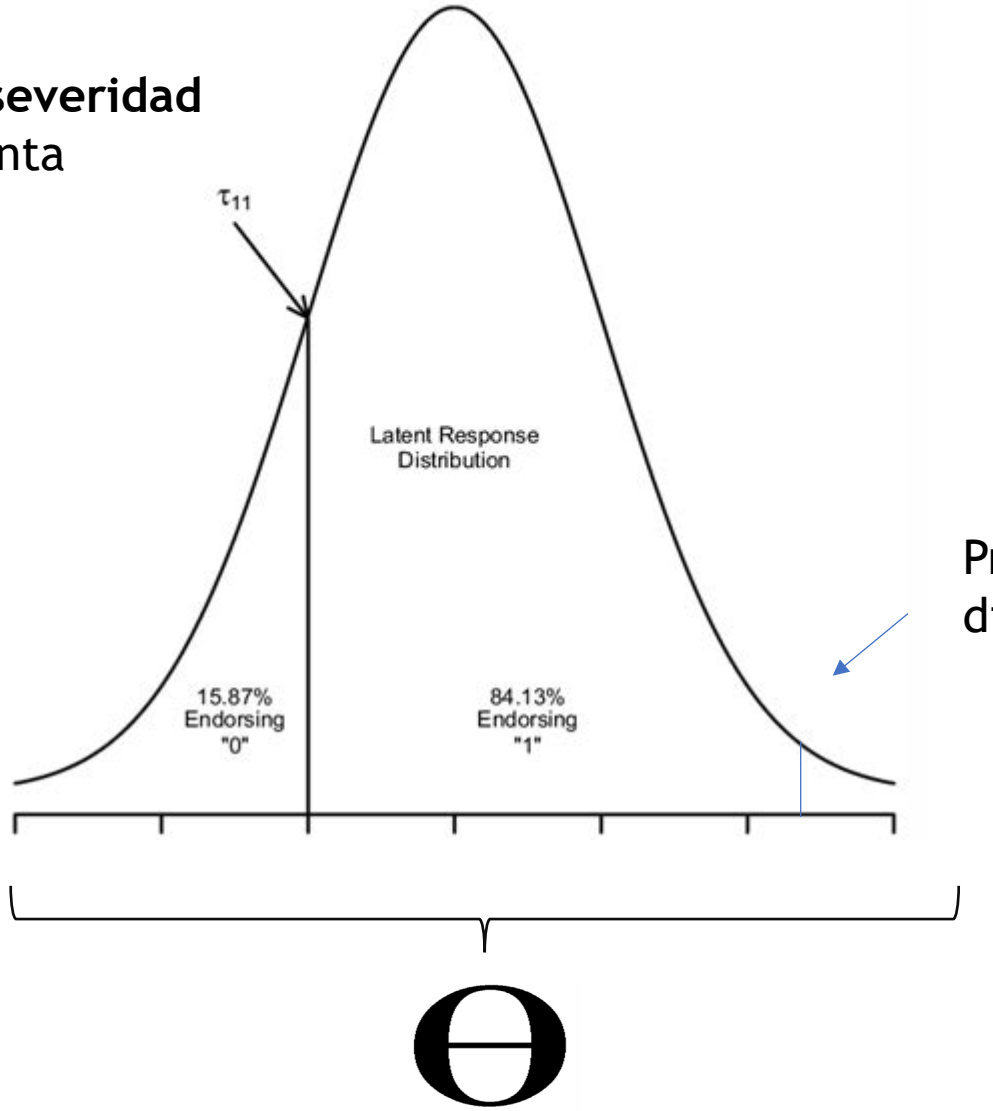


Si las respuestas son manifestaciones de cierto fenómeno (θ), podemos pensar que la matriz observada de respuestas refleja la probabilidad de registrar 1 o 0

Por ejemplo, si θ es el nivel latente de precariedad laboral, esperaríamos que personas con niveles distintos tuvieran probabilidades diferentes de respuesta a cierta pregunta

Incluso podemos pensar que su respuesta es condicional a qué tan severa (difícil) es la pregunta. Por ejemplo, no es lo mismo "tener un salario" a "contar con seguridad social completa".

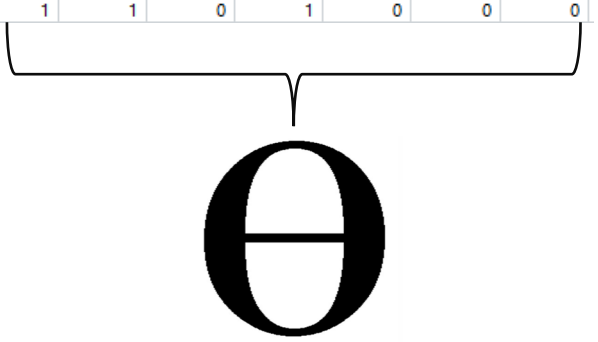
La
dificultad/severidad
de la pregunta



Pregunta más difícil

Variables latentes y probabilidad de respuesta

1	0	1	0	1	1	1	1
2	1	0	1	0	0	0	1
3	0	1	1	1	1	0	0
4	0	0	0	0	0	1	1
5	0	0	1	0	0	1	0
6	1	1	1	1	0	1	0
7	0	0	0	0	0	1	0
8	1	1	1	1	0	0	1
9	0	0	0	0	0	0	0
10	1	0	0	1	0	0	0
11	0	0	0	1	1	0	0
12	1	1	0	0	1	1	1
13	1	0	0	1	0	1	1
14	1	0	0	1	0	1	1
15	1	0	1	1	0	1	0
16	0	1	0	1	0	0	1
17	1	0	1	1	1	0	1
18	1	0	0	0	0	1	0
19	1	1	0	1	0	0	0



Si las respuestas son manifestaciones de cierto fenómeno (θ), podemos pensar que la matriz observada de respuestas refleja la probabilidad de registrar 1 o 0

Por ejemplo, si θ es el nivel latente de precariedad laboral, esperaríamos que personas con niveles distintos tuvieran probabilidades diferentes de respuesta a cierta pregunta

Incluso podemos pensar que su respuesta es condicional a qué tan severa (difícil) es la pregunta. Por ejemplo, no es lo mismo "tener un salario" a "contar con seguridad social completa".

Podríamos pensar también que la probabilidad de respuesta depende de qué tan bien una pregunta distingue (discrimina) entre sujetos con valores diferentes. Por ejemplo, la seguridad social puede hacer un mejor trabajo en distinguir a dos personas con niveles distintos de θ que tener contrato

Teoría de respuesta al ítem

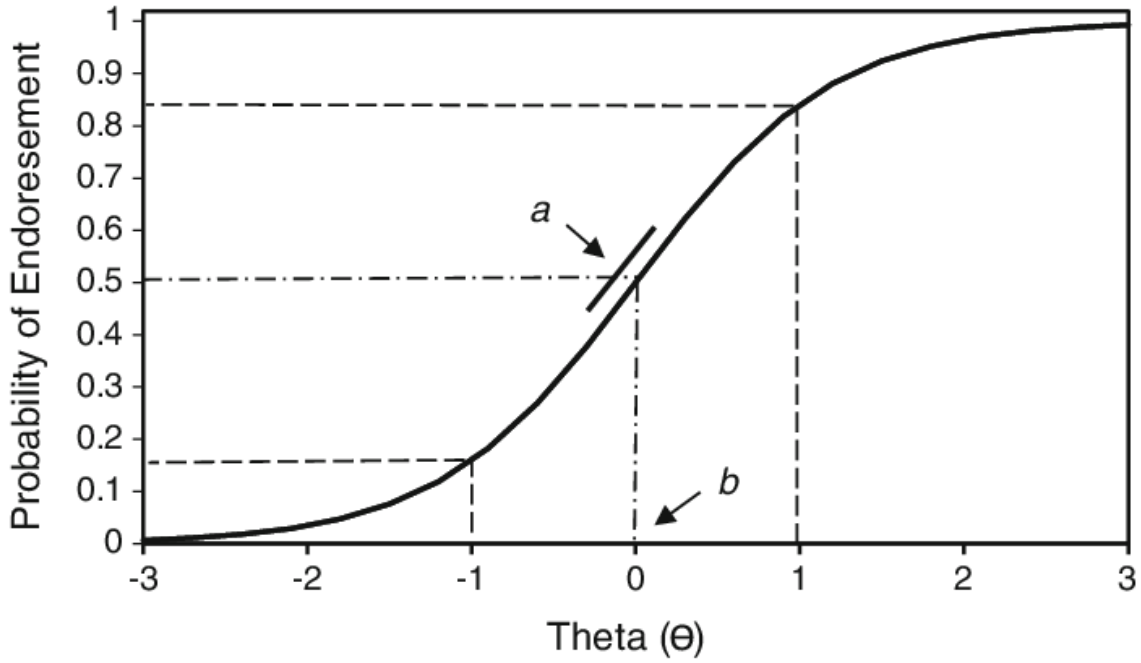
- Parte de que las unidades de análisis tienen un valor latente respecto al fenómeno de interés: θ (Es estructural)
- Las respuestas (score observados) son una probabilidad condicional a θ y otros posibles parámetros
  - Severidad / Dificultad
  - Discriminación
  - Suerte

- Estos tres son sujetos a perturbaciones

TRI o IRT en inglés

$$P\left(X_{ij}=1\,|\,\theta,a,b_i\right)=\frac{e^{Da\left(\theta_j-b_i\right)}}{1+e^{Da\left(\theta_j-b_i\right)}} \qquad (14.1)$$

where P means probability, $X=1$ means that the item is correct (or the response is 1), and the symbol | means "conditional on." So we read $P(X_{ij}=1|\,\theta_j, a, b_i)$ as: The probability of a correct response to item i by examinee j conditional on examinee j's ability and the difficulty (b_i) of the item. The wording "conditional on" simply means that the probability of a correct response can (and usually does) depend on the examinee's ability level and the item difficulty. The expression $P(X_{ij}=1|\,\theta_j, a, b_i)$ is often shortened to $P(\theta)$, which will be used in the remainder of the model description.



TRI de un parámetro

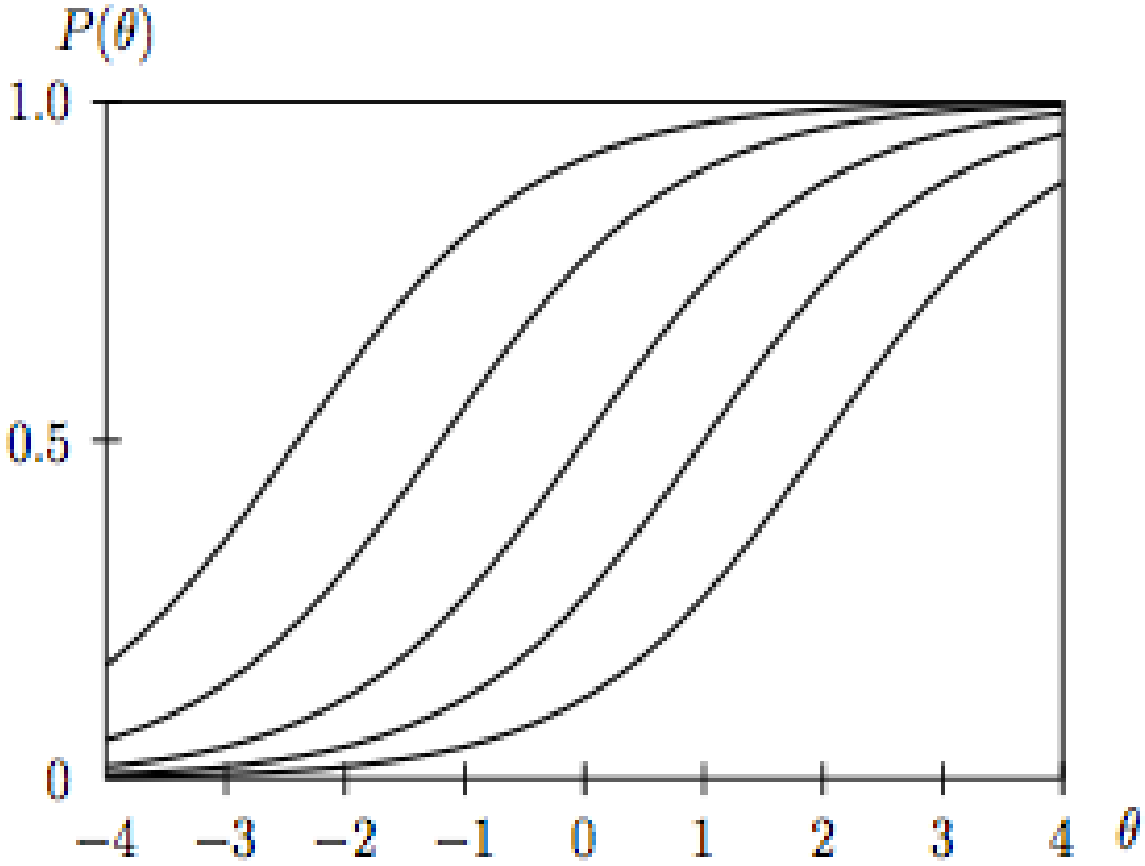
El TRI de un parámetro sólo usa “b” (Severidad / Dificultad)

Asume que todos los indicadores “Discriminan” igual.

También se le conoce como modelo Rasch (Aunque la gente que sigue Rasch NO estarían muy de acuerdo).

Rasch quería separar cualquier relación que pudiera tener el “examinado” del “test”.

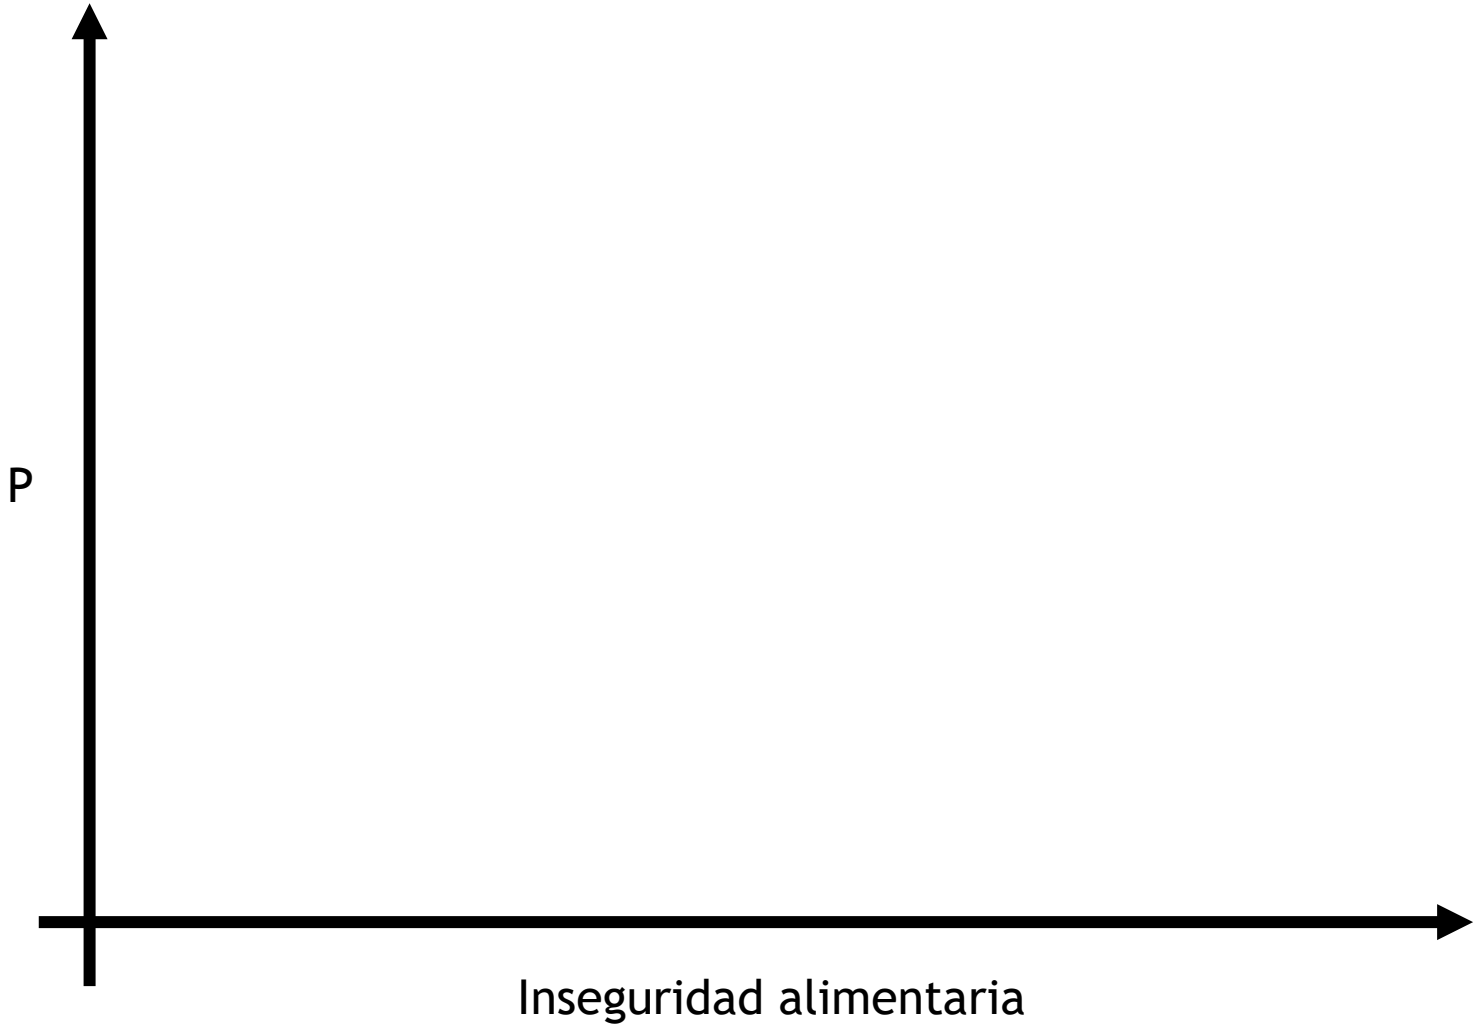
IRT ve la interacción entre ambos



Explicación de pizarrón

EMSA: Por falta de recursos en los últimos tres meses

1. Tuvieron poca variedad de alimentos
2. Se quedaron todo un día sin comida
3. Los adultos no tuvieron alguna de las tres comidas



Rasch vs TRI de un parámetro

Food and Agriculture Organization of the United Nations

The Food Insecurity Experience Scale:

Measuring food insecurity through people's experiences

In September 2015, **the 193 Member States of the United Nations adopted** the 2030 Agenda for Sustainable Development to succeed the Millennium Development Goals.The UN Statistical Commission (UNSC) agreed in March 2016 on a global indicator framework comprising 230 indicators to monitor targets and measure progress towards achievement of the 17 new Sustainable Development Goals (SDGs).

The UNSC created the Inter Agency and Expert Group on SDG indicators (IAEG-SDG), **whose members are the chief statisticians (or their delegates) of 28 countries**, elected on a rotating basis and representing all UN regions. The group includes regional and **international agencies as observers** with no deliberating power but who play an important advisory role.

IAEG-SDG has **appointed FAO to serve as custodian of 21 indicators**. FAO's responsibilities include maintaining the methodology needed to properly compile these indicators, providing technical support to countries, receiving data/indicators from countries to maintain a global database, and producing regional and global aggregates to report to the UN Department of Economic and Social Affairs (UNDESA).

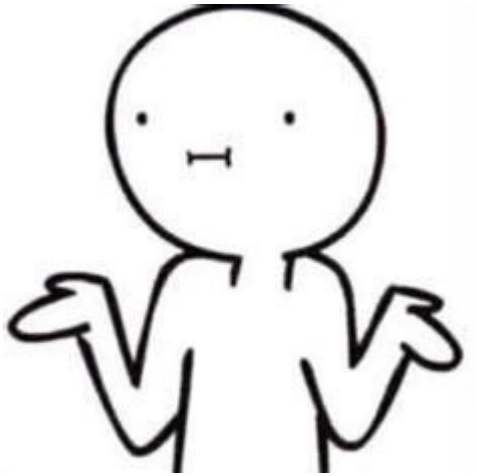
Lo importante es qué tanto se parecen los datos a la teoría

El modelo es correcto y los datos deben ajustarse



Rasch vs TRI de un parámetro

Resto de la comunidad estadística: Los modelos son imperfectos y lo mejor que podemos hacer es evaluar si resultan en una buena representación del mundo observado



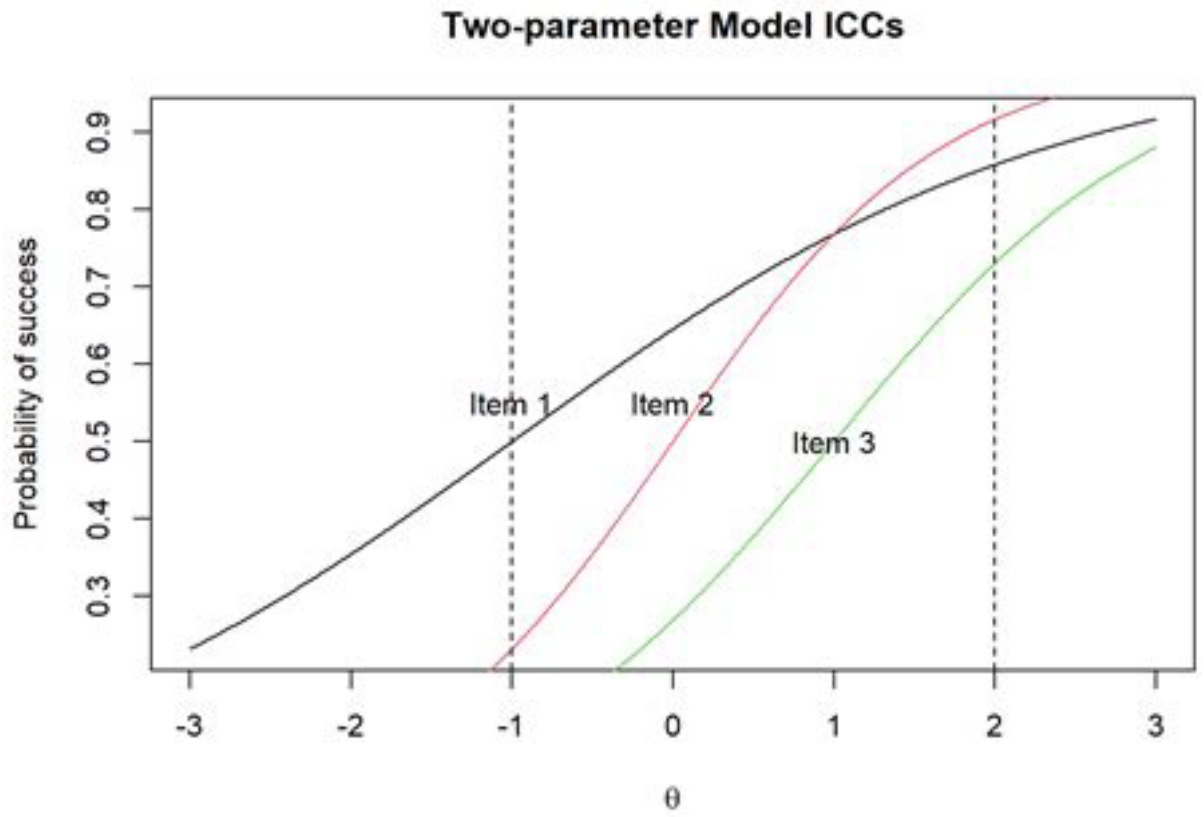
Rasch: Los datos deben ajustar al modelo

TRI: Los modelos deben ajustar a los datos

TRI dos parámetros:

Severidad: Eje de las x

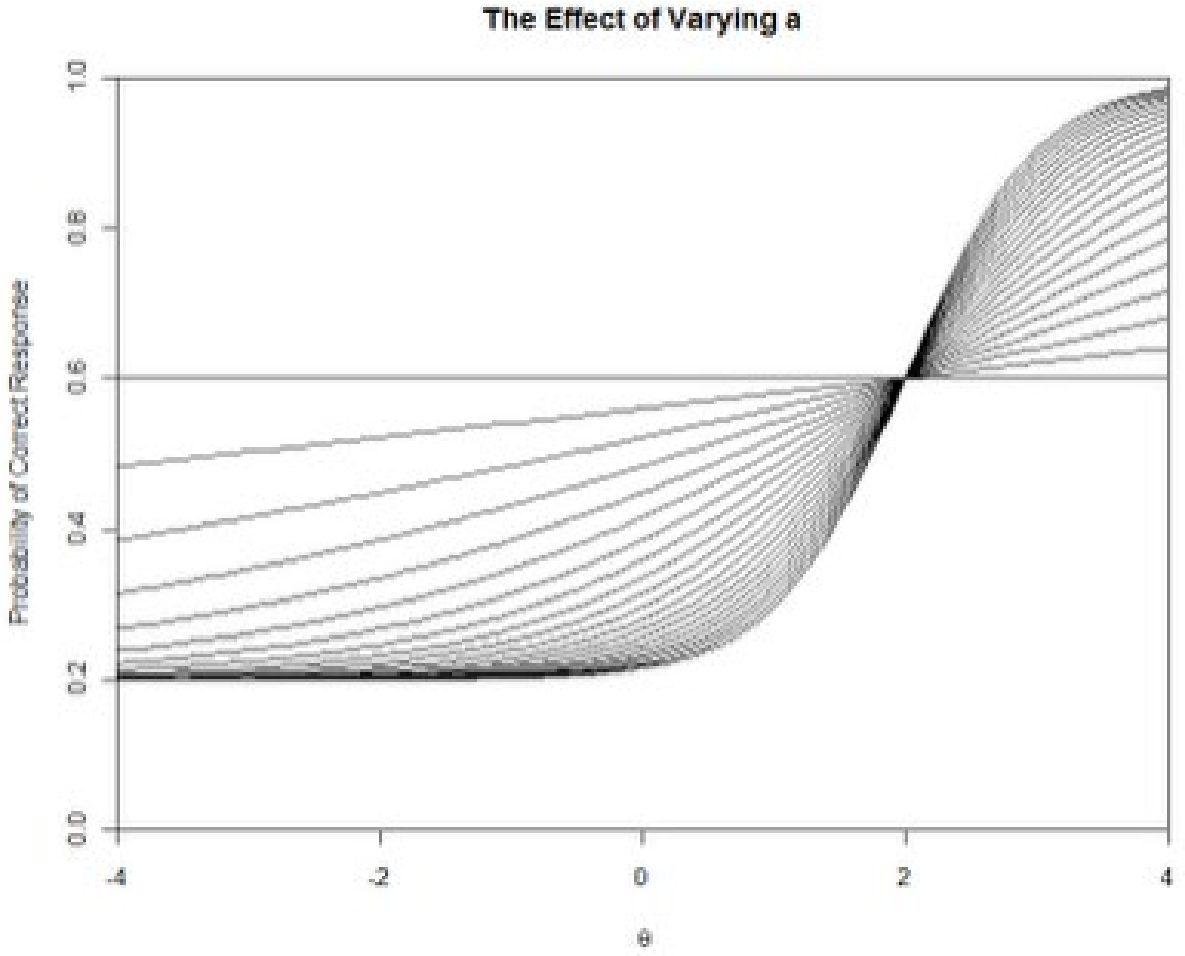
Discriminación: Pendiente



La importancia de la pendiente

¿Qué curva nos hablaría de un mal indicador?

¿Qué quisiéramos en un buen indicador?



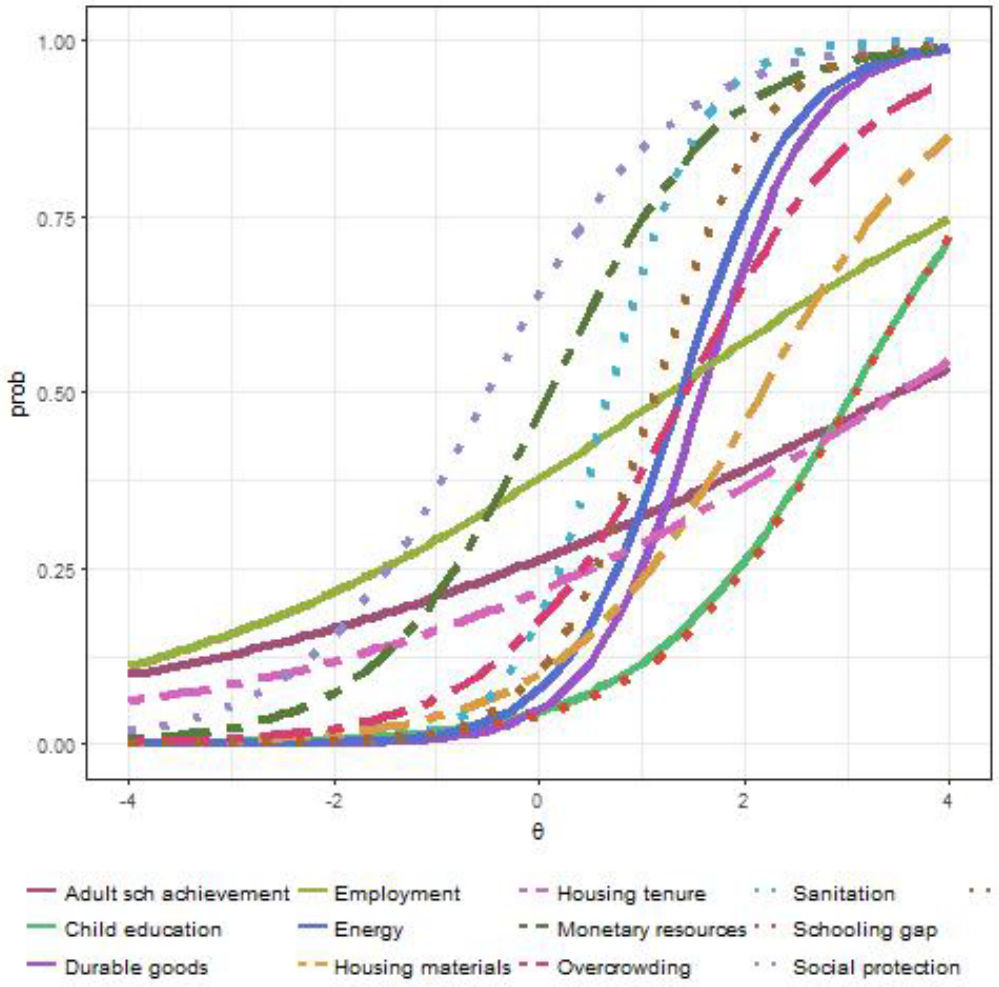
Explicación de pizarrón

EMSA: Por falta de recursos en los últimos tres meses

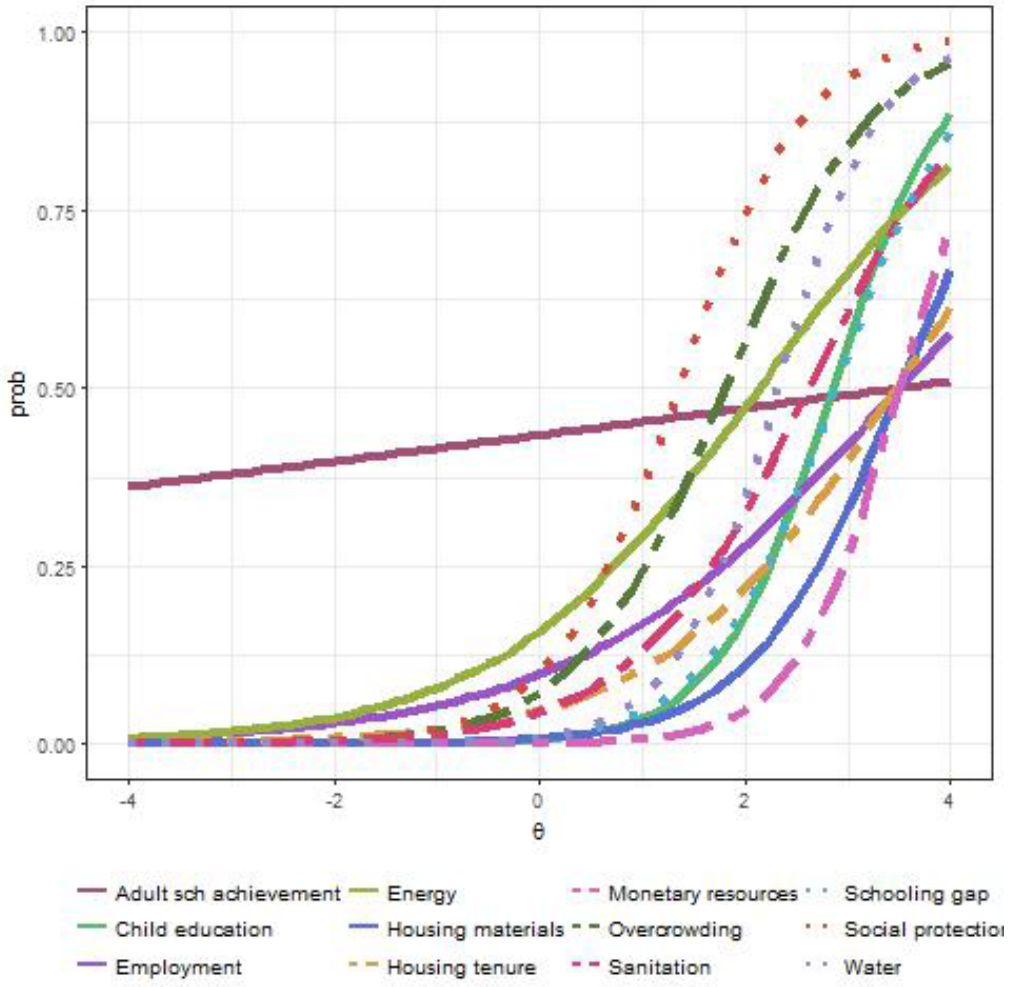
1. Tuvieron poca variedad de alimentos
2. Se quedaron todo un día sin comida
3. Los adultos no tuvieron alguna de las tres comidas
4. Los adultos no tomaron cerveza



Ejemplo



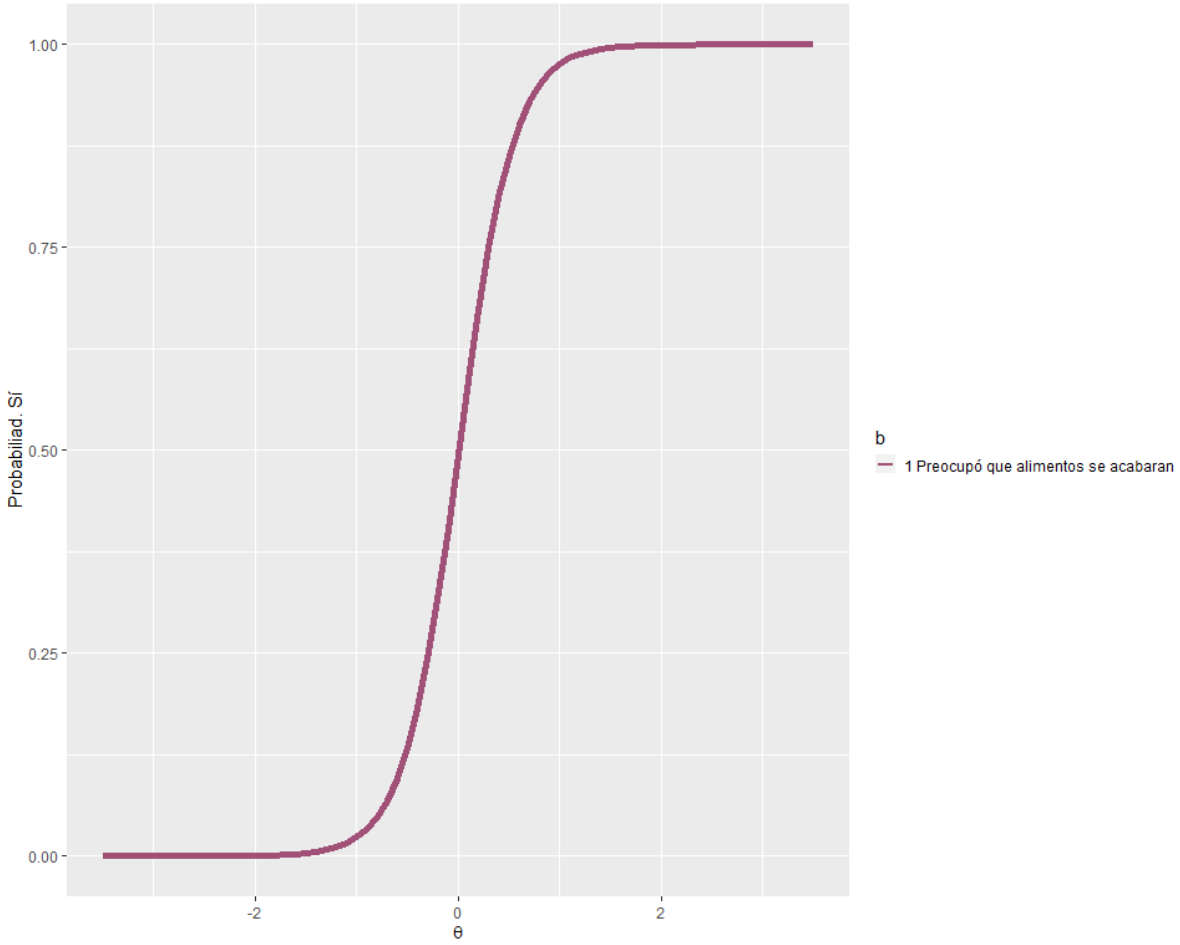
México (2012)



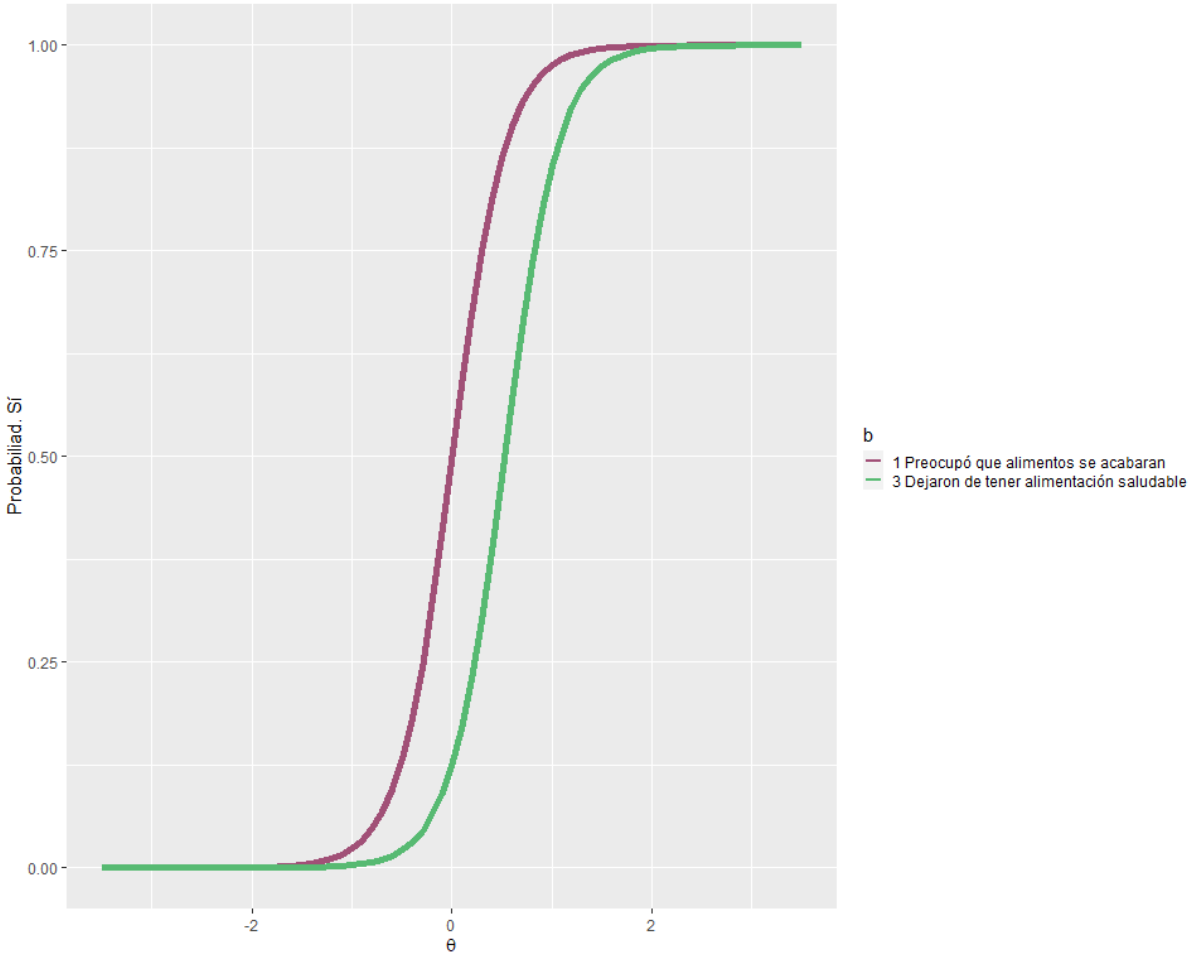
Argentina 2012

Nájera y Gordon (2019)

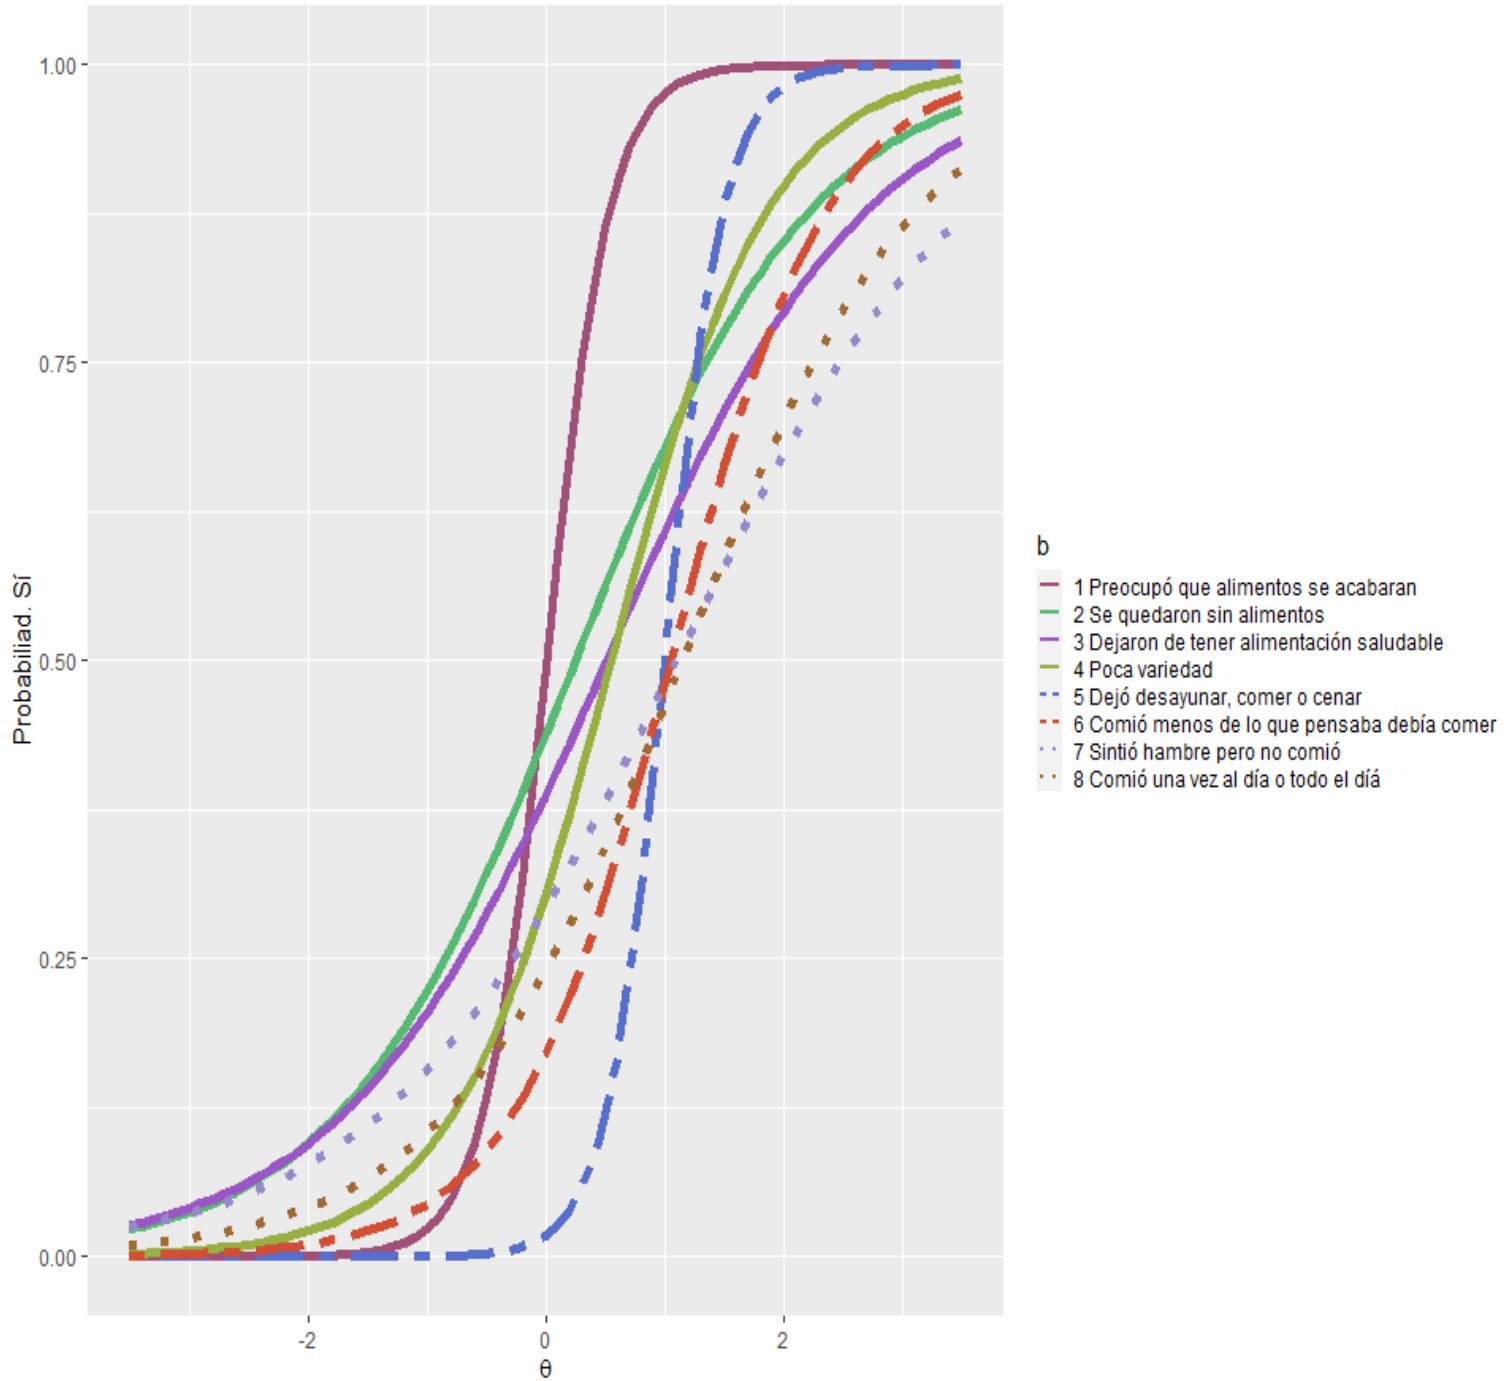
Ejemplo: Modelo de un parámetro (severidad)



Curvas características. Modelo de un parámetro (Rasch). Adultos



Curvas características. Modelo de un parámetro (Rasch). Adultos


1.00
0.75
0.50
0.25
0.00
Probabiliad. Sí
-2
0
2
θ
b
1 Preocupó que alimentos se acabaran
2 Se quedaron sin alimentos
3 Dejaron de tener alimentación saludable
4 Poca variedad
5 Dejó desayunar, comer o cenar
6 Comió menos de lo que pensaba debía comer
7 Sintió hambre pero no comió
8 Comió una vez al día o todo el día

¿Uno o dos parámetros?

- La ventaja de TRI, al igual que en CFA, es que podemos comparar modelos usando estadísticos globales de ajuste
  - TLI, CFI, BIC, AIC, BICn
  - Podemos saber qué modelo hacer un mejor ajuste de los datos.

Supuestos básicos de TRI

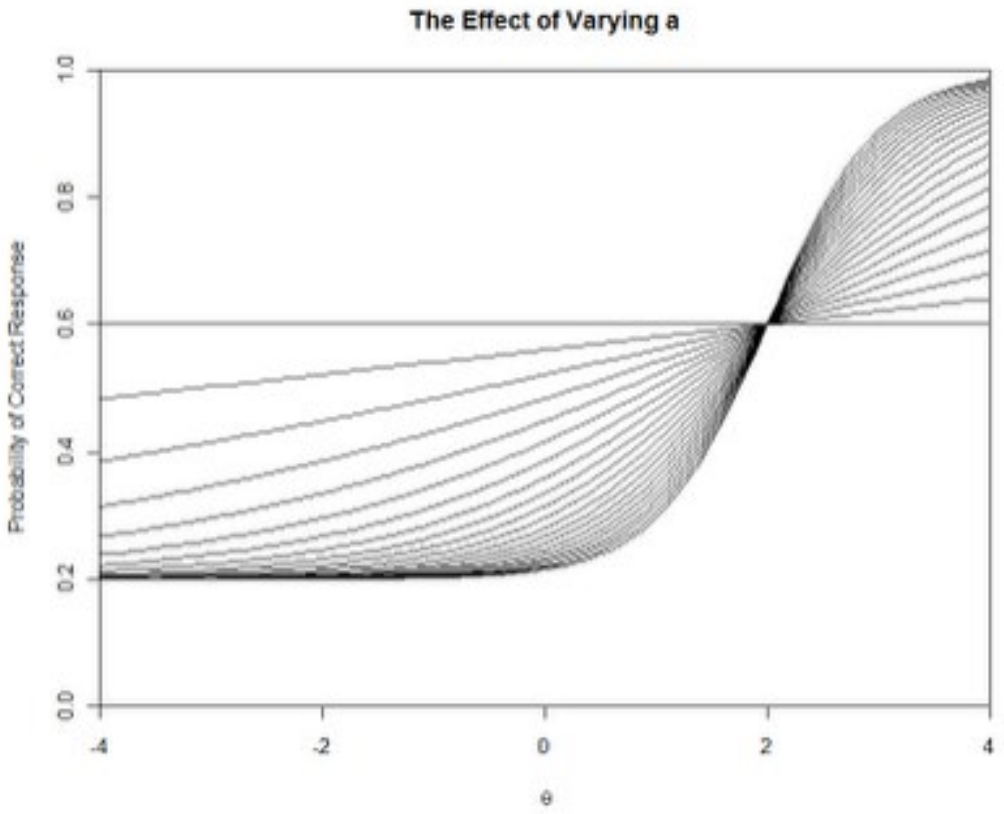
- Dimensionalidad: Están pensados para modelos unidimensionales, aunque pueden acomodar modelos multidimensionales
- Independencia local: La variación se debe al factor y la correlación entre ítems se debe al factor
- Forma funcional: Relación entre el factor y las respuestas

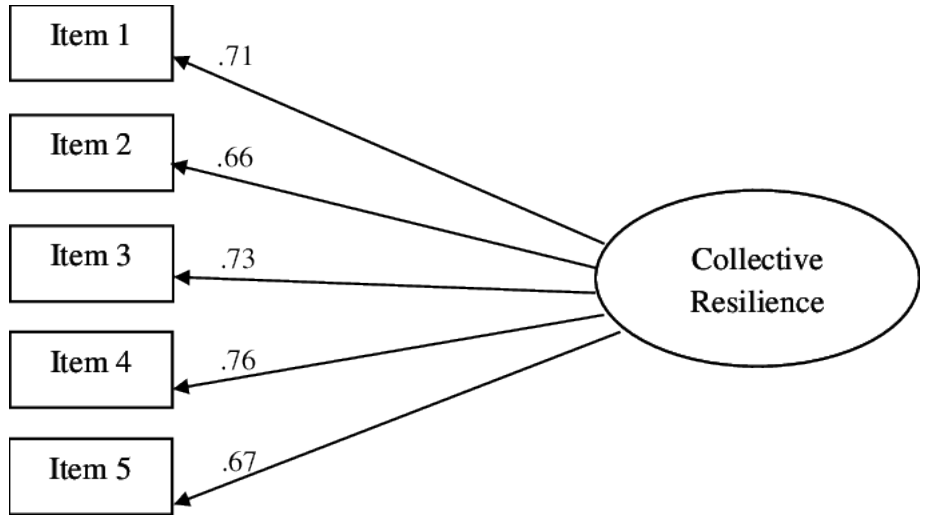
Relación entre TRI y análisis factorial

- Parecen tener varios aspectos en común
- ¿Cuál puede ser la relación entre TRI y análisis factorial?
- Piensen en los parámetros de un modelo unidimensional
  - Discriminación - - - Carga factorial

- También pueden aplicarse a variables nominales y ordinales
  - Polytomous response theory

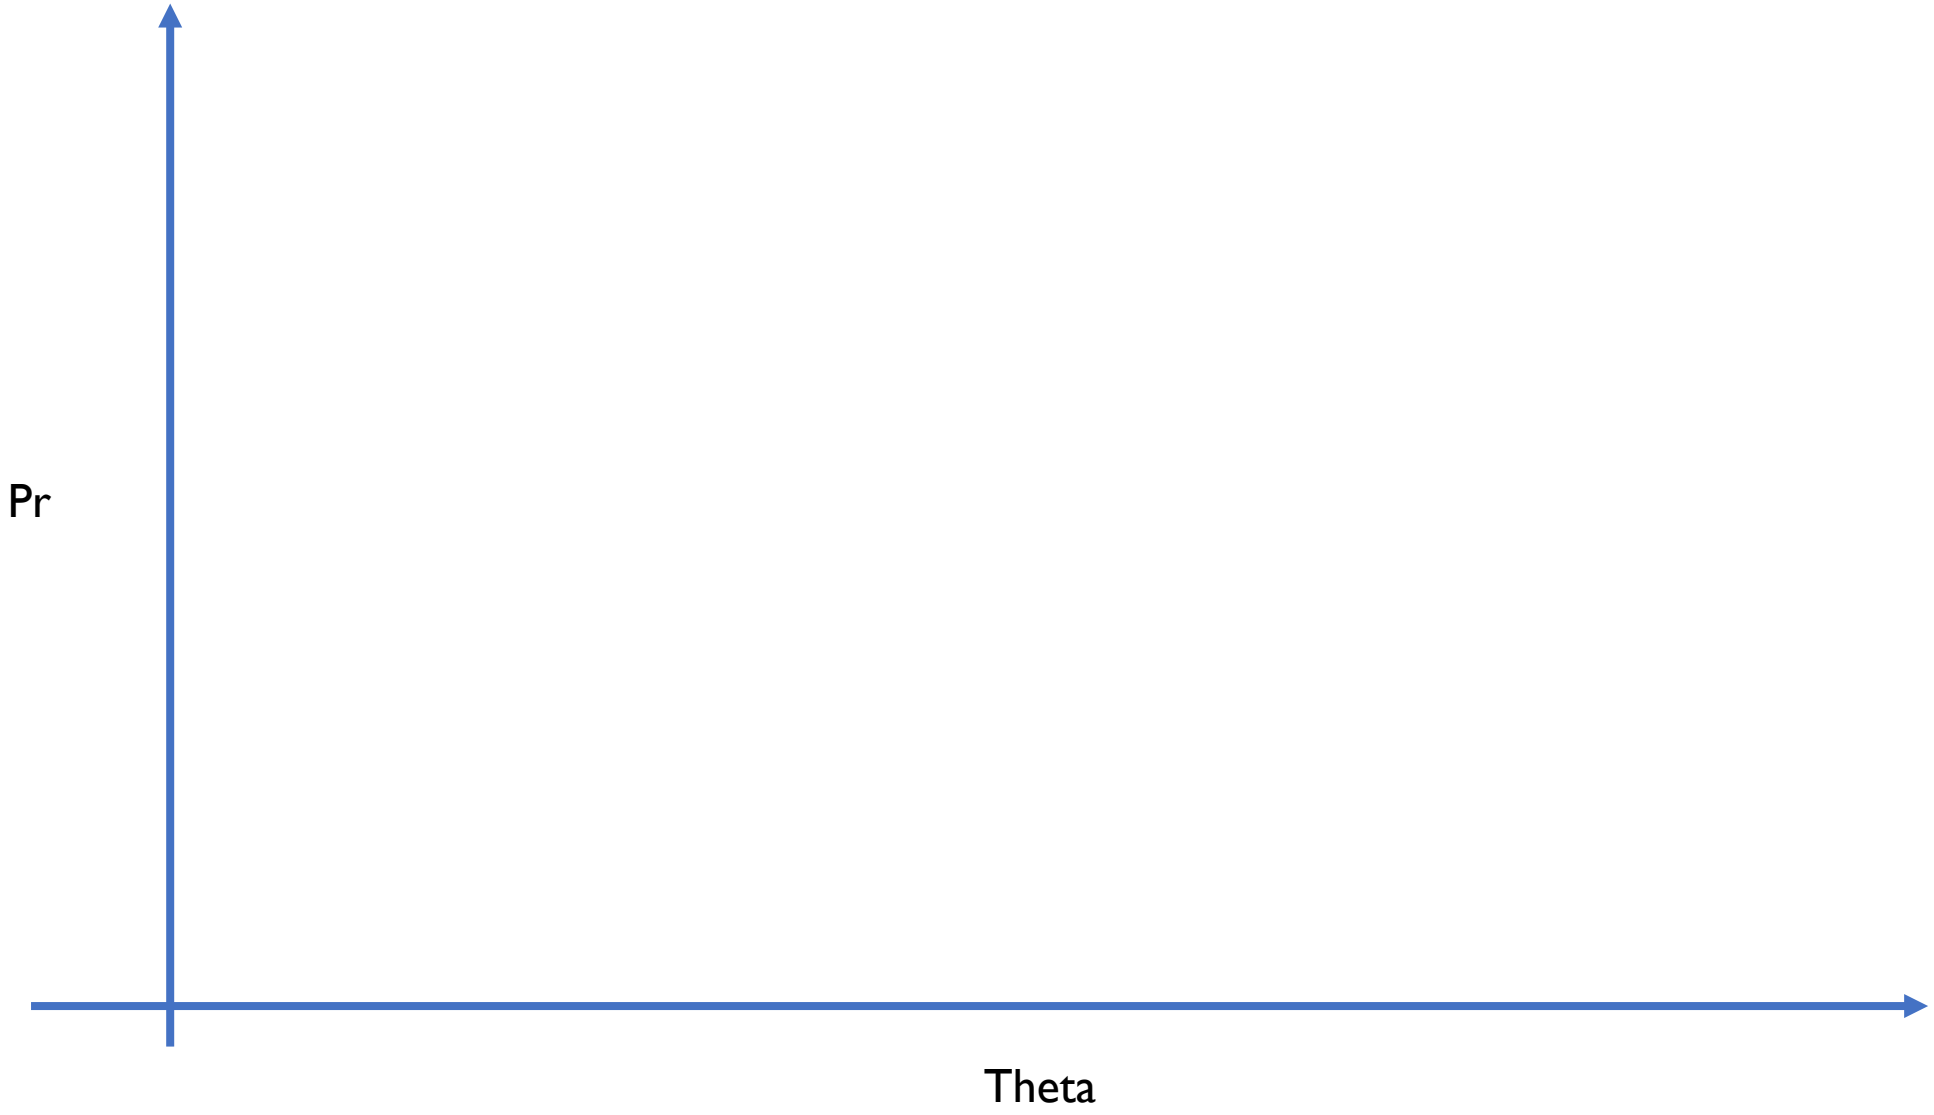
Parámetro de discriminación ~ carga factorial





Son equivalentes. La diferencia es la parametrización (Logit v métrica del factor)

- Si las respuestas fueran casi aleatorias ¿Cómo se verían las curvas?



- Si las cargas factoriales son altas ¿Cómo lucirían las curvas?



Evaluación de discriminación y dificultad

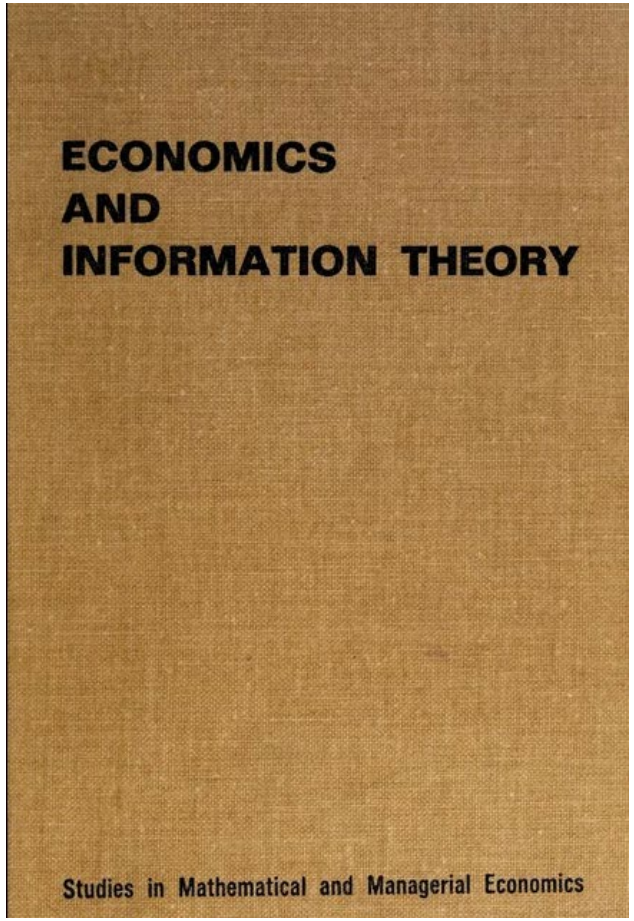
- Discriminación baja es definitivamente indeseable. Qué bajo es muy bajo: .9 (~.4 con cargas factoriales estandarizadas).
- Un modelo TRI o factorial con bajas cargas factoriales es un mal modelo.
- Severidad. Depende del estudio, pero extremos >+3 o <-3 desviaciones estándar difícilmente va a ser útil

TRI y teoría de la información

- Claude Shannon 1948
  - Información:Todo aquello de un mensaje que no nos sorprende –señal-
  - Entropía: Medida de la cantidad de información una vez que conozco el resultado

  TRI: Respuestas aleatorias tienen poca información (alta entropía). Si la discriminación me dice la probabilidad de respuesta puedo deducir la información

Teoría de la información y desigualdad



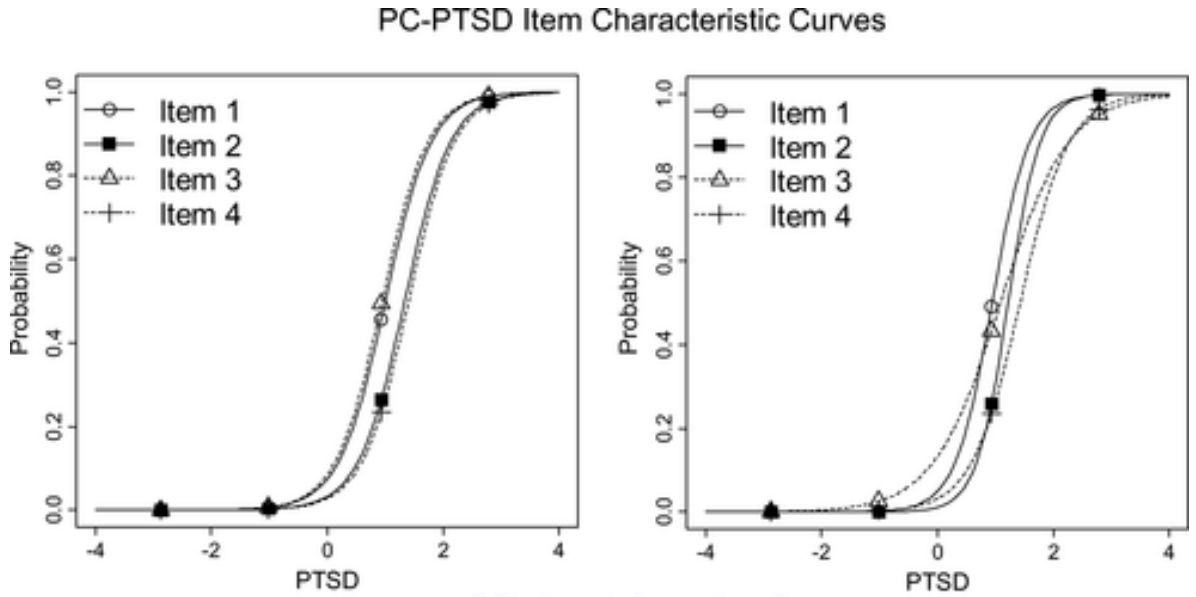
Producción de medidas de desigualdad

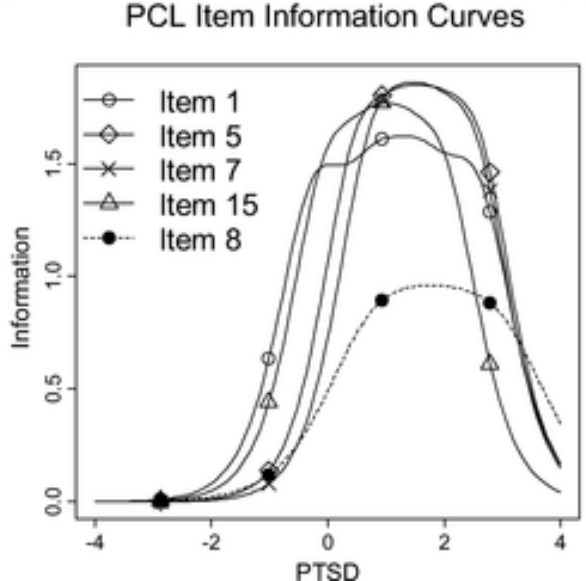
Descomposición comparable bajo índices de Theil

ICC and information curves

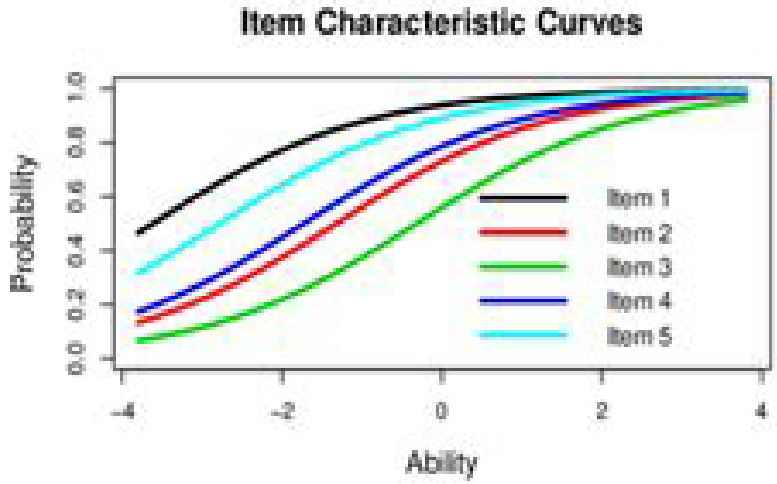
Las curvas de información me ayudan a visualizar “el rango” de la variable latente para el cuál tengo más información

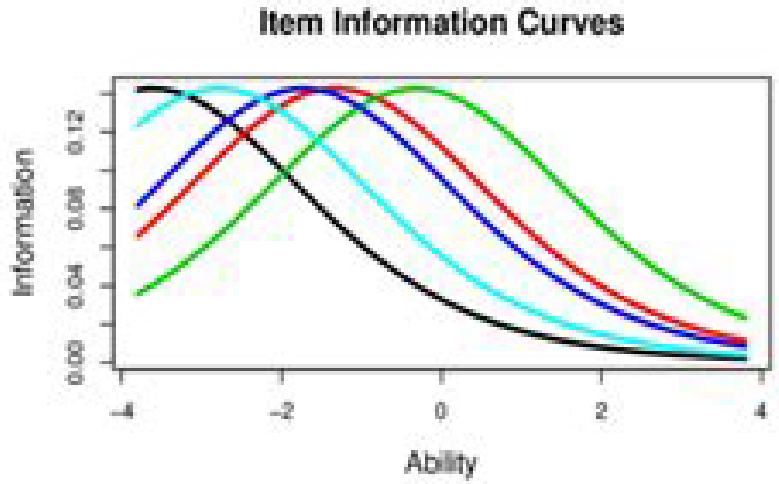
Esto es útil para evaluar confiabilidad relativa

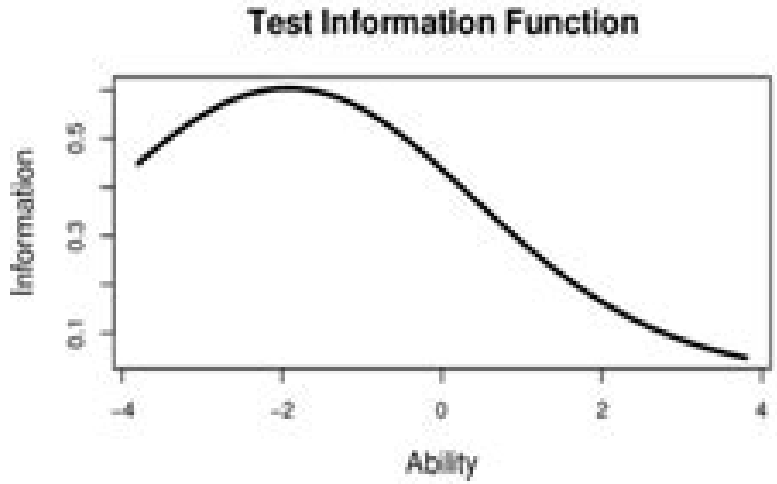




Curvas en TRI







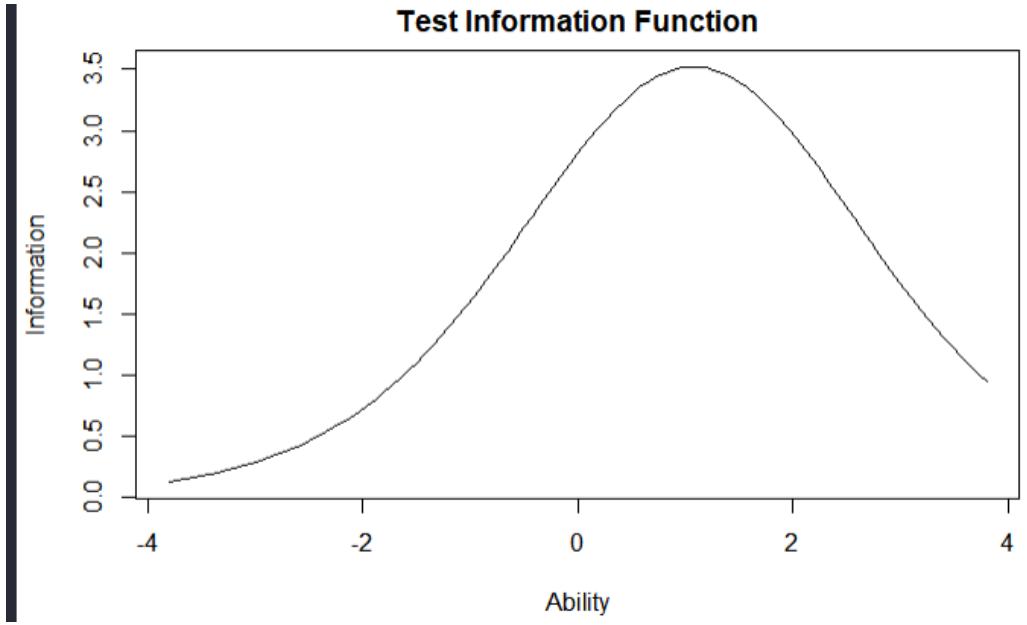
Total Information: 3.763

Information in (−4, 0): 2.165 (57.53%)

Information in (0, 4): 0.768 (20.4%)

Pasando de scores obervados a scores latentes

```
##   Lavadora Televisión Agua entubada Refrigerador GasNatural Drenaje
## 1        0          0              0            0          0       0
## 2        0          0              0            0          0       0
## 3        0          0              0            0          0       0
## 4        0          0              0            0          0       0
## 5        0          0              0            0          0       0
## 6        0          0              0            0          0       0
##   Cisterna Celular Computadora Netflix Panel Solar Jardin Estufa
## 1        0       0           0       0            0      0       0
## 2        0       0           0       0            0      0       0
## 3        0       0           0       0            0      0       0
## 4        0       0           0       0            0      0       0
## 5        0       0           0       0            0      0       1
## 6        0       0           0       0            0      0       1
##   AireAcondicionado Bicicleta Obs        Exp         z1     se.z1
## 1                 0         0 260 308.583613 -1.3723183 0.6710940
## 2                 0         1  78  26.815590 -0.9565429 0.6137046
## 3                 1         0  80  25.740288 -0.9565429 0.6137046
## 4                 1         1  31   3.339630 -0.6034440 0.5701628
## 5                 0         0 100  27.592368 -0.9565429 0.6137046
## 6                 0         1  32   3.579925 -0.6034440 0.5701628
```

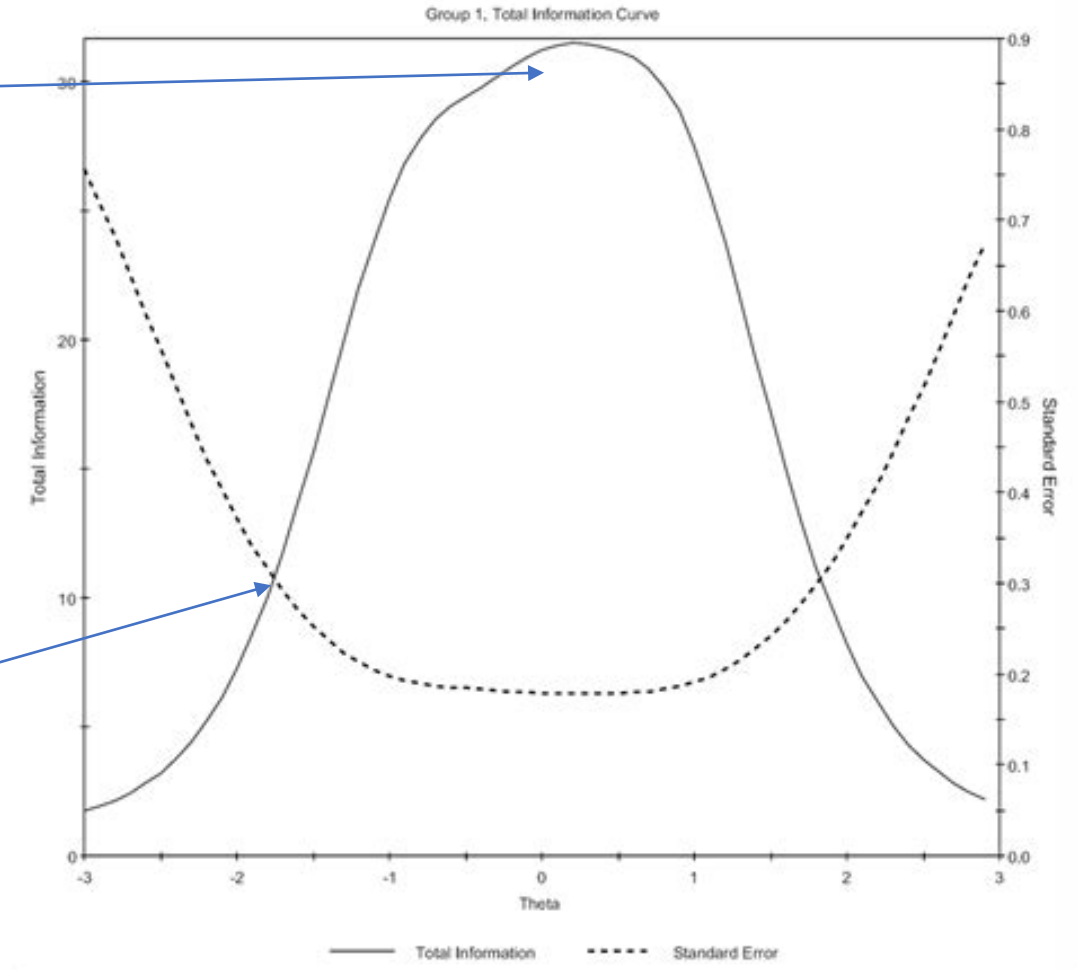


¿Cómo se obtienen?

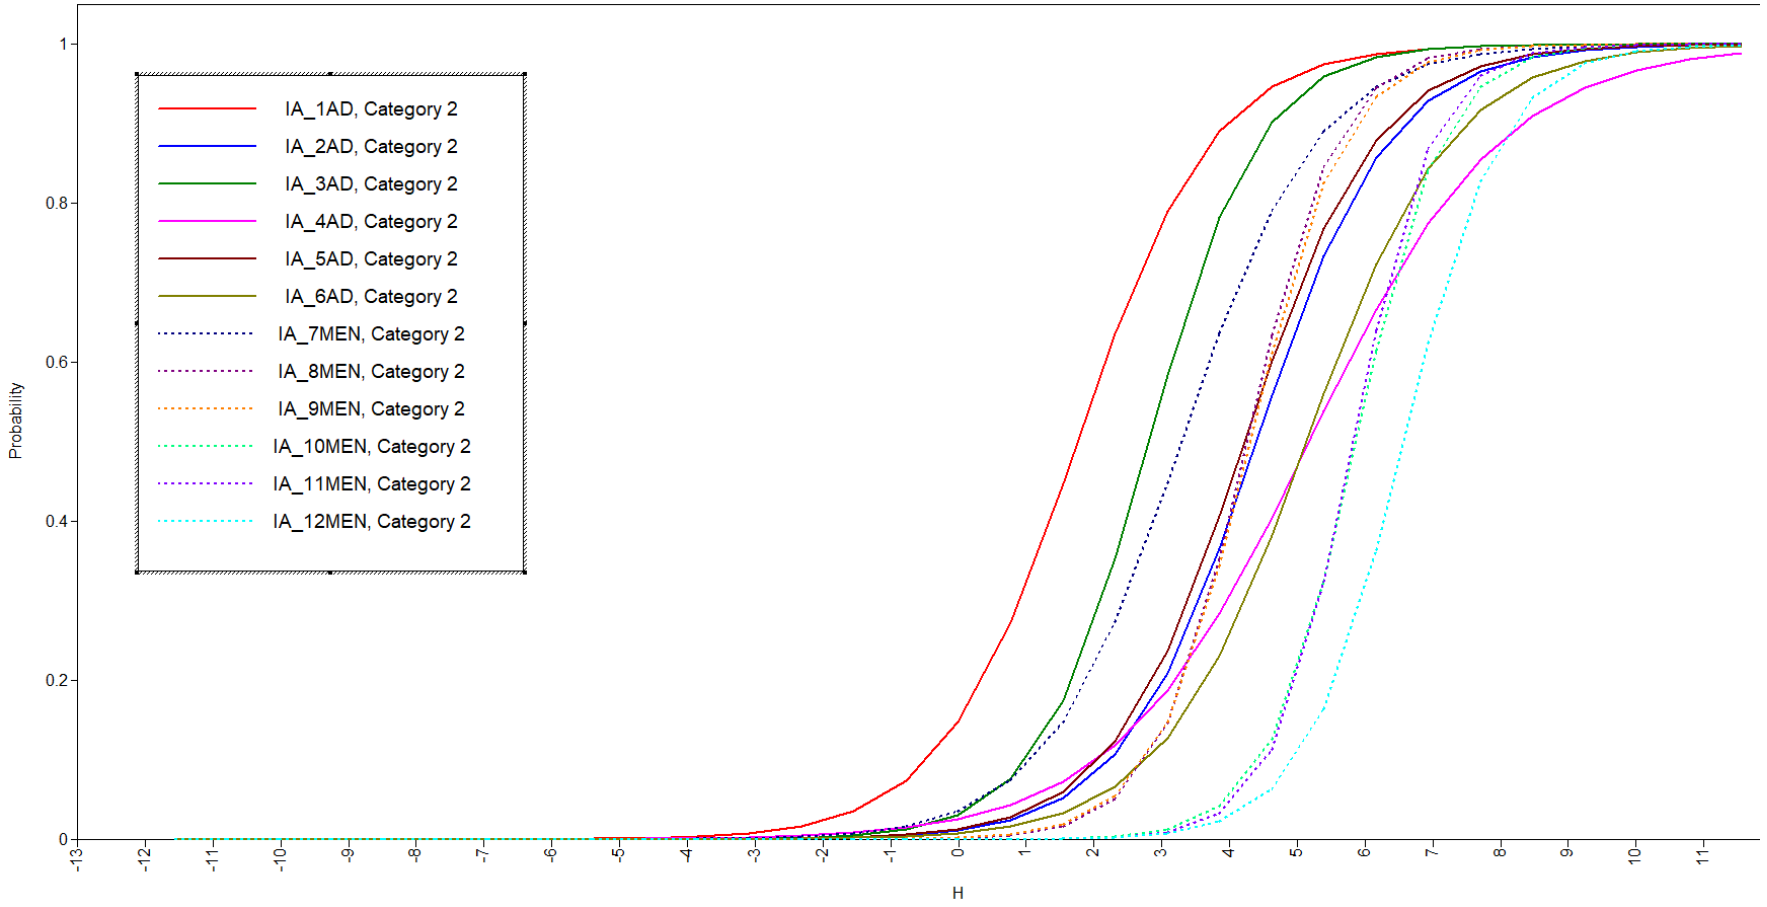
Curva de información

Mucha información: Podemos hacer inferencia

Poca información: No podemos hacer buenas inferencias

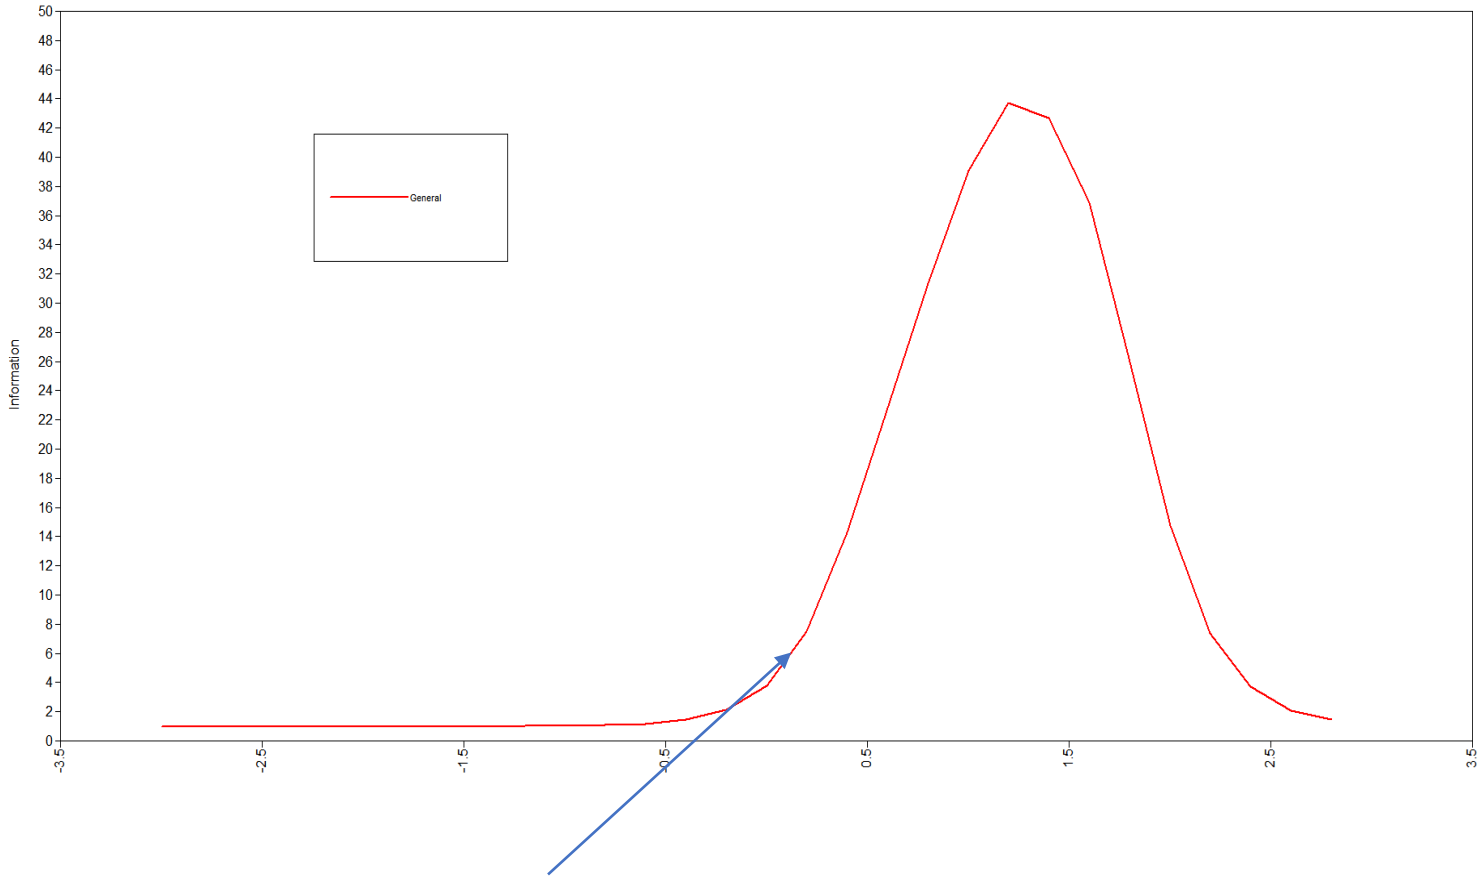


Ejemplo: Escala Alimentaria




```
##        param   est
## 13    IA_1AD 0.455
## 15    IA_3AD 0.729
## 19   IA_7MEN 0.854
## 17    IA_5AD 1.096
## 20   IA_8MEN 1.105
## 21   IA_9MEN 1.118
## 14    IA_2AD 1.141
## 18    IA_6AD 1.333
## 16    IA_4AD 1.343
## 23  IA_11MEN 1.512
## 22  IA_10MEN 1.522
## 24  IA_12MEN 1.705
```

Total Information Curve

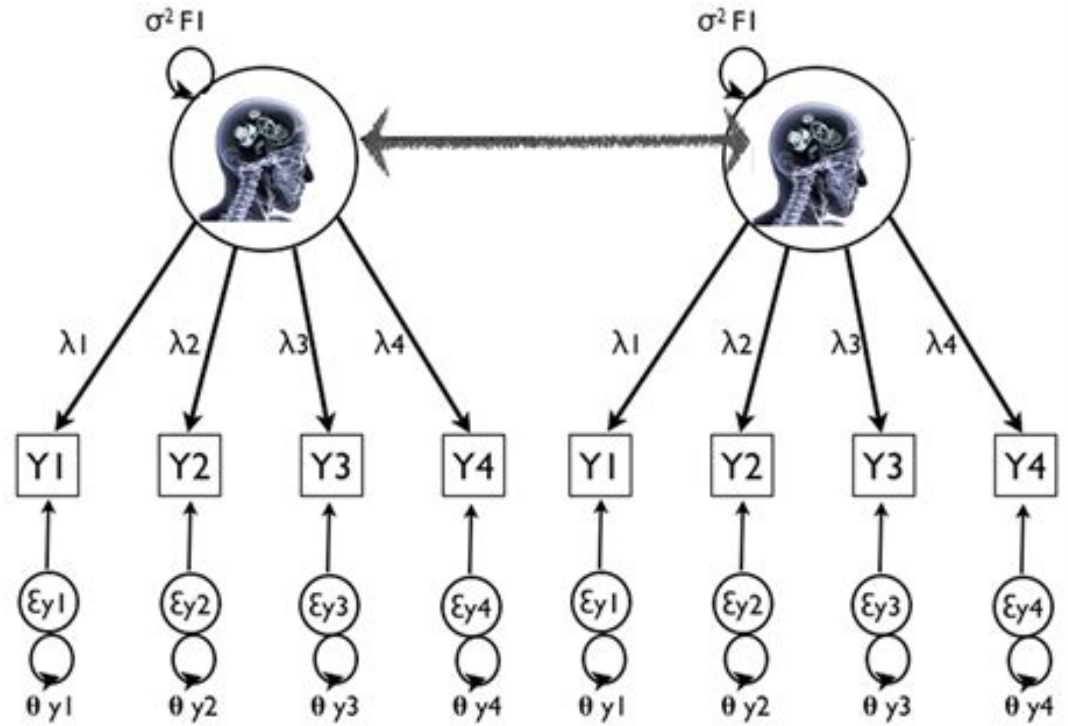


##	TIC	SEE	REL
## 1	1	1.00	0.00
## 2	2	0.71	0.50
## 3	3	0.58	0.67
## 4	4	0.50	0.75
## 5	5	0.45	0.80
## 6	6	0.41	0.83
## 7	7	0.38	0.86
## 8	8	0.35	0.88
## 9	9	0.33	0.89

Poca información

Usos de TRI

- Comparación de los puntajes de grupos a partir de variables categóricas



PISA



Studies in Educational Evaluation

Date: March 2021

Article: 100965

Volume: Volume 68

View accessibility information

Published by

ELSEVIER

Research article Get rights and content ↗

Testing measurement invariance of PISA 2015 mathematics, science, and ICT scales using the alignment method

Bryce Odell ✉, Mark Gierl ✉, Maria Cutumisu ✉ Show more

Cite Add to Mendeley Share | 10.1016/j.stueduc.2020.100965 ↗

Access through **your organization** Purchase PDF

Article preview | Recommended articles | Cited by (22) | Metrics

Highlights

- This study investigates measurement invariance of the mathematics, science, and ICT scales.
- Forty-seven participating countries in the PISA 2015 *ICT Familiarity Questionnaire* were included.
- The Alignment method was employed to test the measurement invariance of the three scales.
- Results show that mathematics and science scores are highly invariant across countries.
- The ICT scale is mostly non-invariant across the countries included in this study.

Article preview

Abstract
Introduction
Section snippets
References (62)

PISA

OECD Topics Countries & regions Publications Data News & events About English

OECD > Publications > PISA 2022 Results (Volume I) > Full Report >
Are PISA mathematics scores comparable across countries and languages?

PISA 2022 Results (Volume I)

The State of Learning and Equity in Education

Report

More info

PISA • 5 December 2023



Summary Full report Support materials

Available in: English français

Download PDF Cite this publication

Disclaimers
Preface
Foreword
Acknowledgements
Reader's Guide +
Executive Summary +
PISA 2022 key results (infographic) +

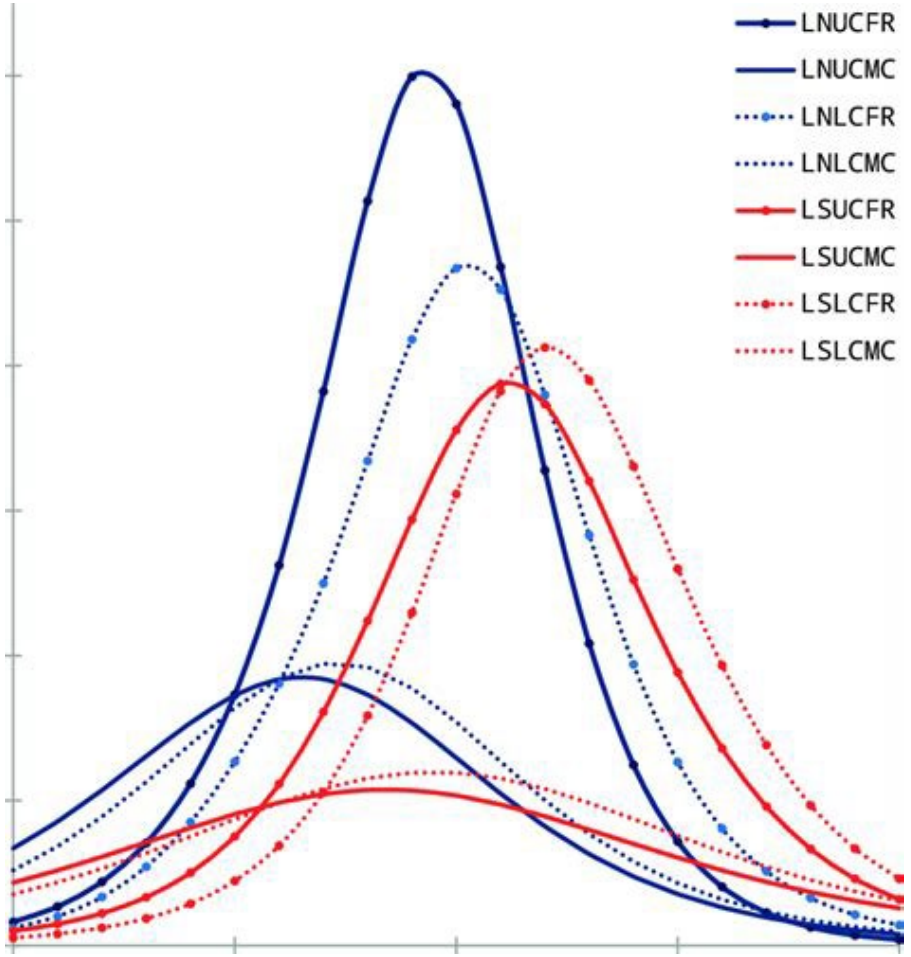
Annex A6. Are PISA mathematics scores comparable across countries and languages?

The validity and reliability of PISA scores, and their comparability across countries and languages are the key concerns that guide the development of assessment instruments and selection of the statistical model for scaling students' responses. The procedures used by PISA to meet these goals include qualitative reviews conducted by national experts on the final main study items and statistical analyses of model fit in the context of multi-group item-response-theory models, which indicate the measurement equivalence of each item across groups defined by country and language.

Usos TRI: Comparación de escalas

Comparar escalas a partir de su información

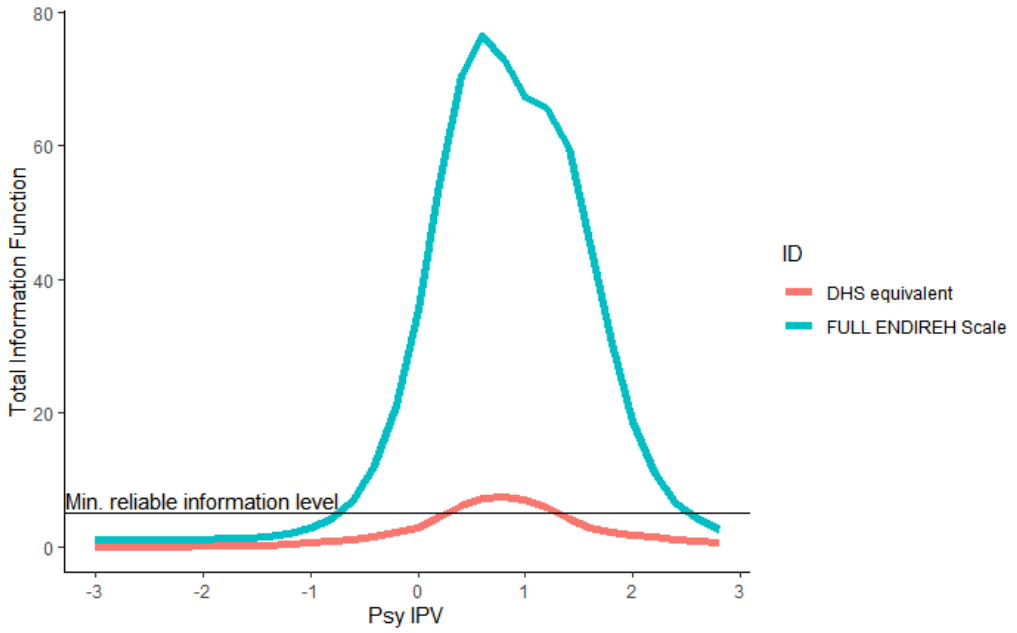
Hay cierta relación entre información y confiabilidad

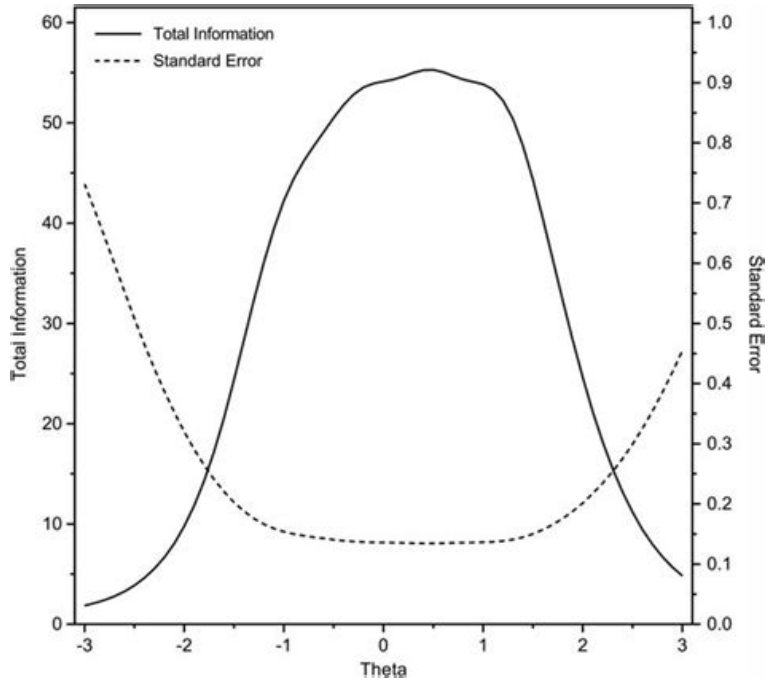


Ejemplo: Escala y subescala

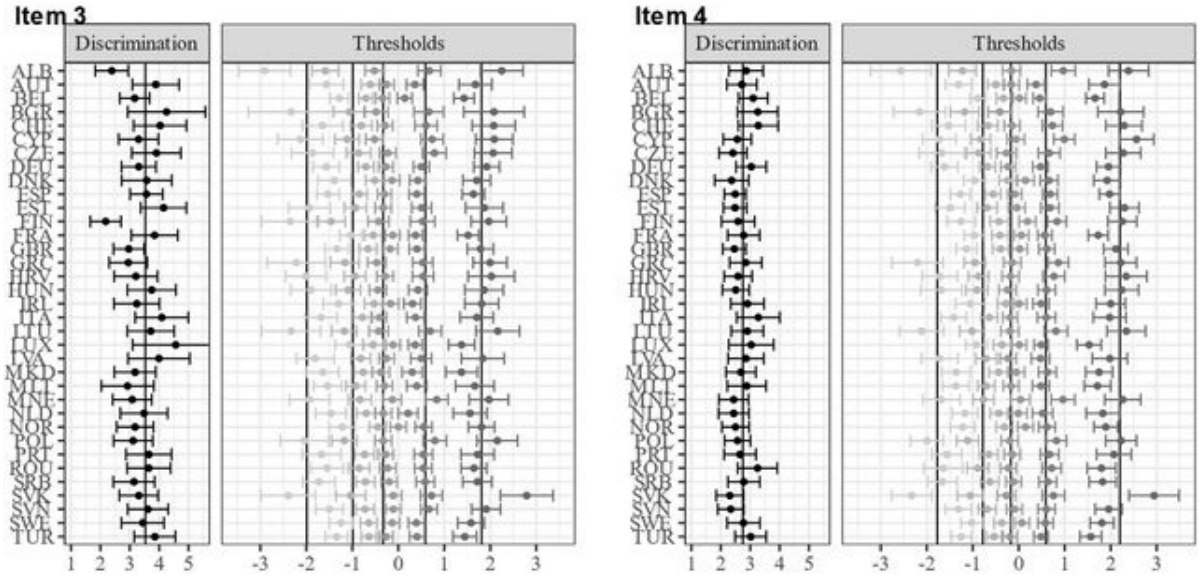
Esta es la información total de una escala –suma de las curvas de información-.

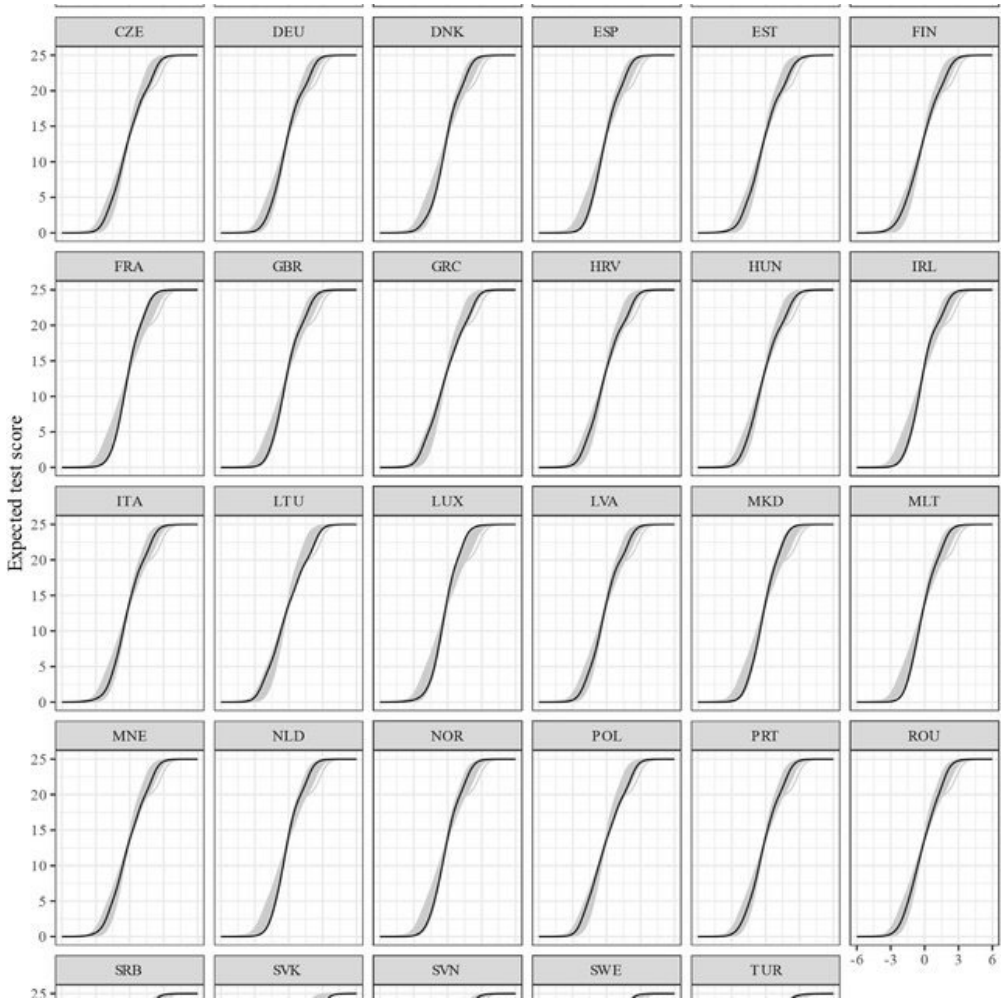
¿Mínimo de información?





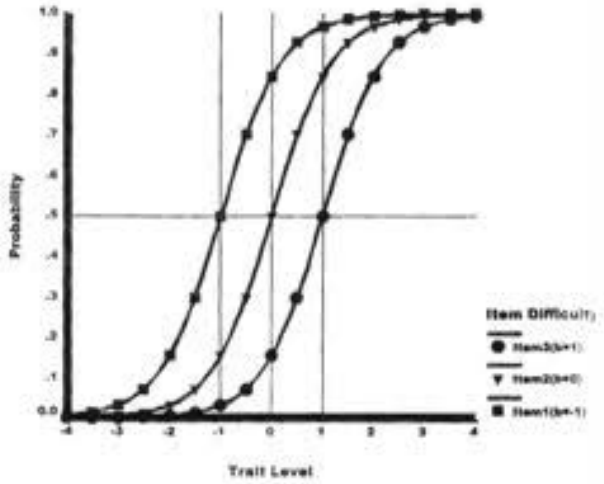
Usos TRI

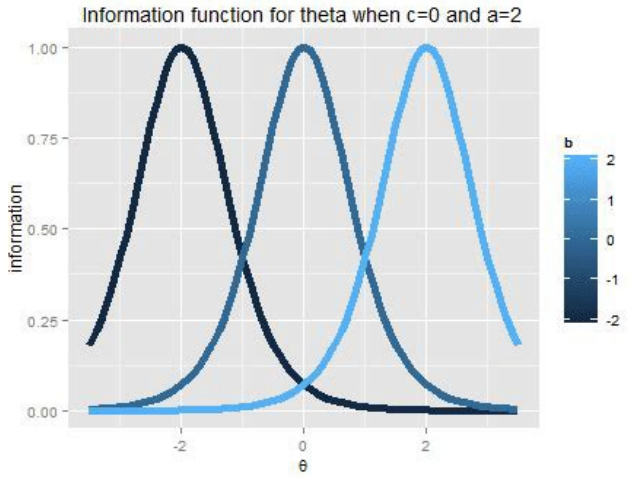




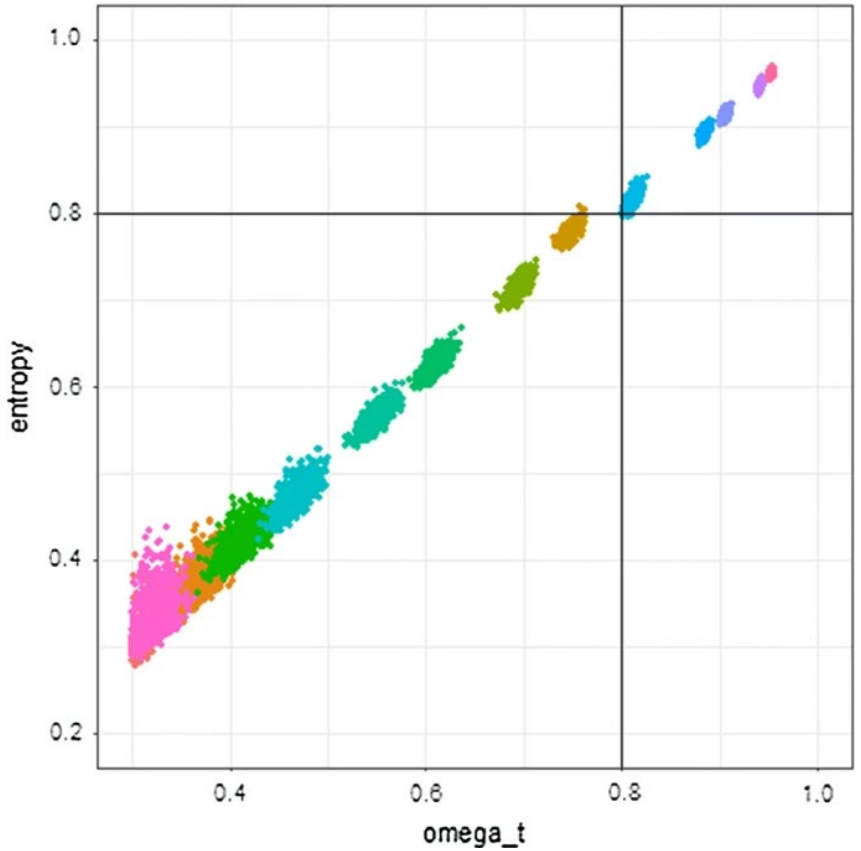
Medición invariante: Mido lo mismo y de la misma manera entre distintos grupos

TRI y clasificación





Entropía relativa



IRT: Avanzado

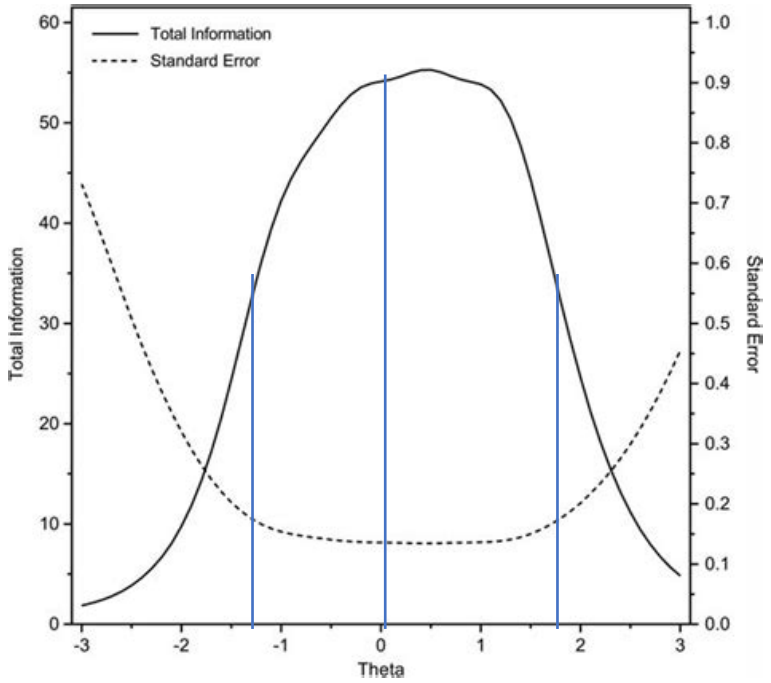
SEM es un marco potente y flexible

IRT es un caso especial de SEM que puede extenderse para abordar distintos problemas de investigación:

- Problemas de clasificación
- Problemas de muchos ceros

Clasificación IRT

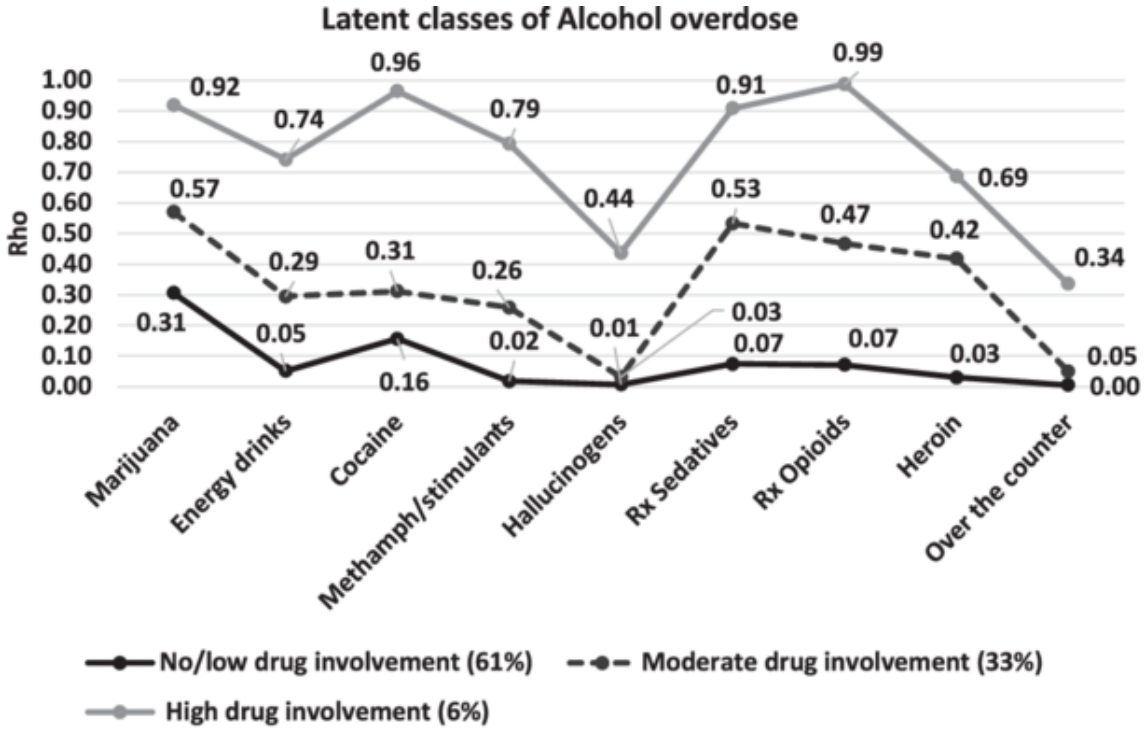
Dado un patrón de respuestas, nos gustaría clasificar a la población en grupos

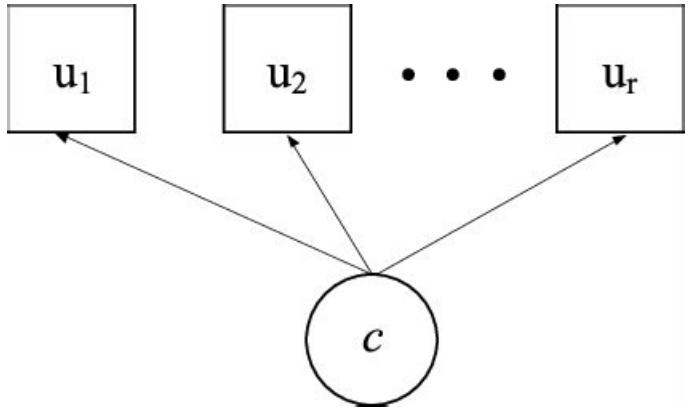




Clasificación IRT

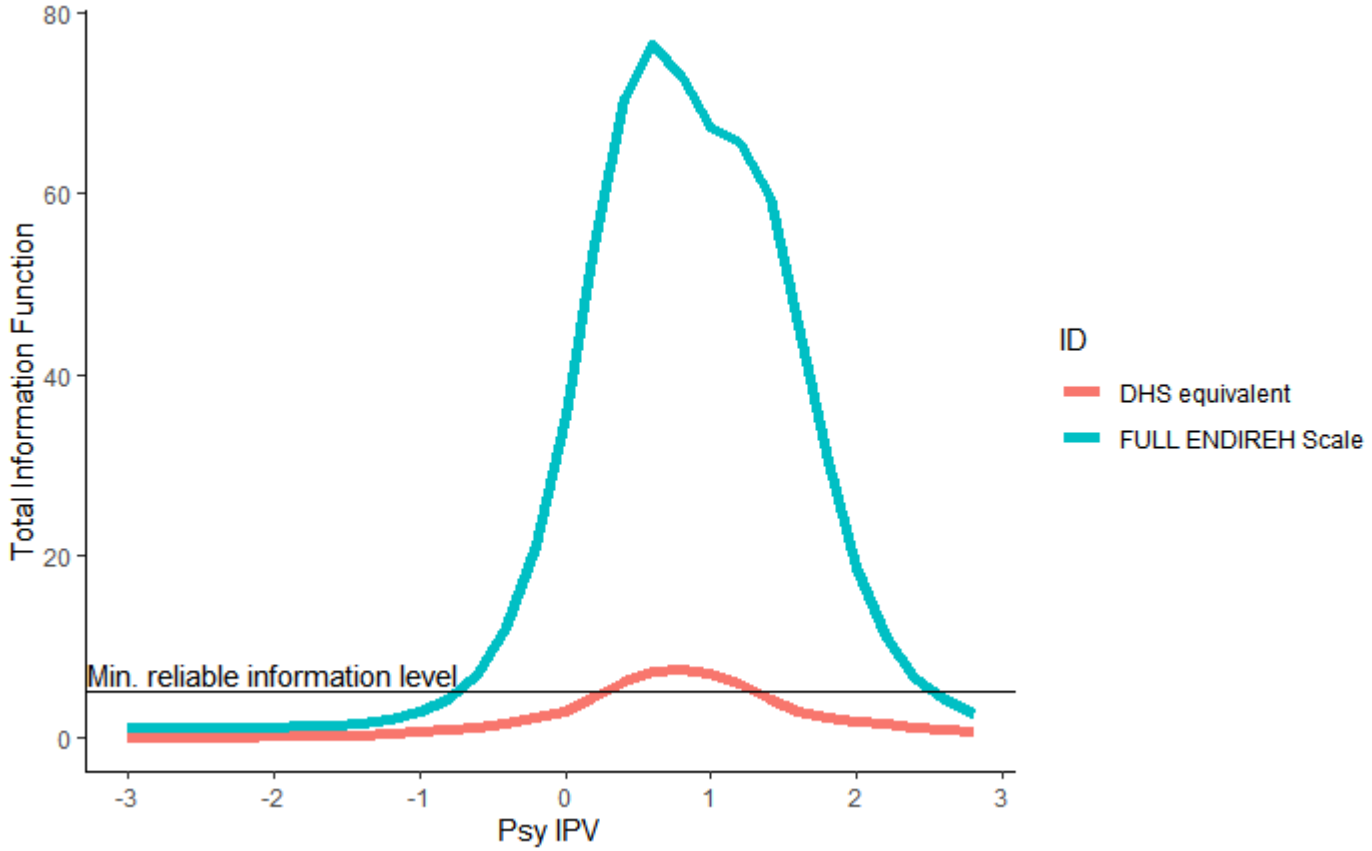
- Análisis de clases latentes (Mixture modelling)





La clasificación será tan buena como la confiabilidad de los scores

IRT: Muchos ceros



Hay mediciones que requieren muchas preguntas para poder estimar con confiabilidad scores para ciertas áreas de la distribución

Cuando no se tienen esas escalas, uno tiene altos falsos positivos y negativos

IRT + Clases latentes

- ¿Qué tal si combinamos un modelo factorial (IRT) con un modelo de clasificación?

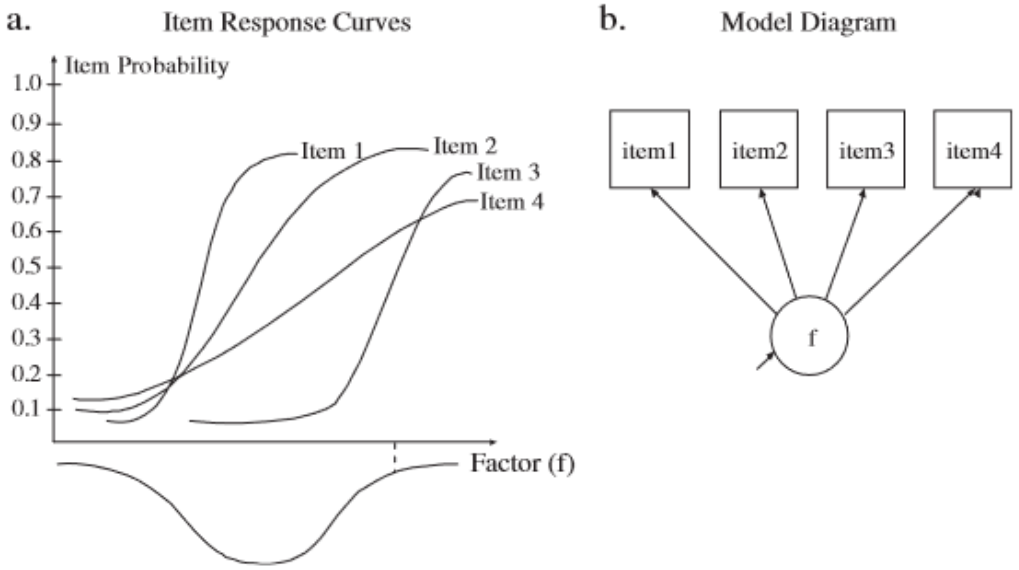
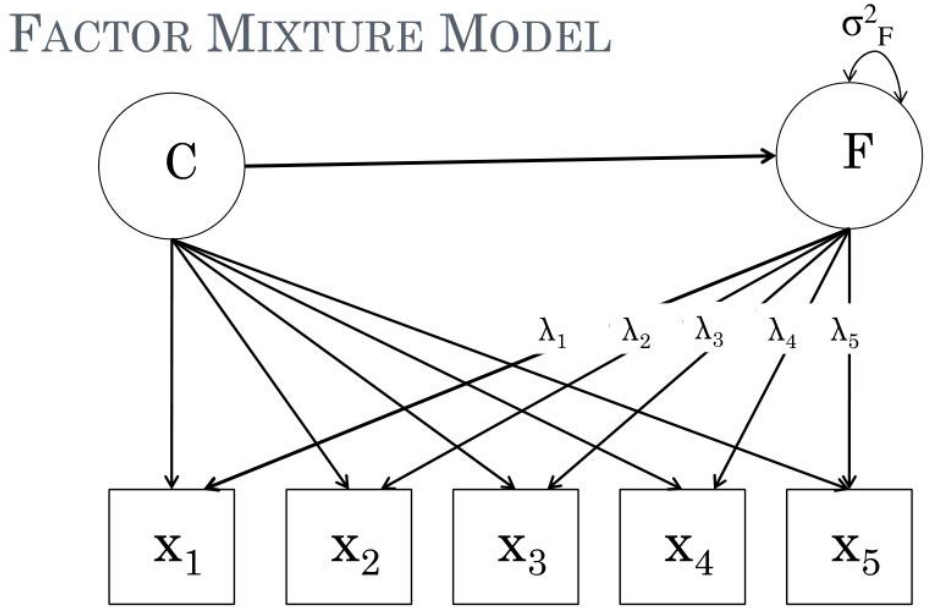


Fig. 1. Uni-dimensional factor analysis.



Classes can be indicated by item thresholds (categorical)\ item means (continuous) or factor mean and variance

IRT + Clases latentes

› Psychol Methods. 2005 Mar;10(1):21-39. doi: 10.1037/1082-989X.10.1.21.

Investigating population heterogeneity with factor mixture models

Gitta H Lubke [1], Bengt Muthén [2]

Affiliations + expand

PMID: 15810867 DOI: 10.1037/1082-989X.10.1.21

Abstract

Sources of population heterogeneity may or may not be observed. If the sources of heterogeneity are observed (e.g., gender), the sample can be split into groups and the data analyzed with methods for multiple groups. If the sources of population heterogeneity are unobserved, the data can be analyzed with latent class models. Factor mixture models are a combination of latent class and common factor models and can be used to explore unobserved population heterogeneity. Observed sources of heterogeneity can be included as covariates. The different ways to incorporate covariates correspond to different conceptual interpretations. These are discussed in detail. Characteristics of factor mixture modeling are described in comparison to other methods designed for data stemming from heterogeneous populations. A step-by-step analysis of a subset of data from the Longitudinal Survey of American Youth illustrates how factor mixture models can be applied in an exploratory fashion to data collected at a single time point.

IRT + Clases latentes

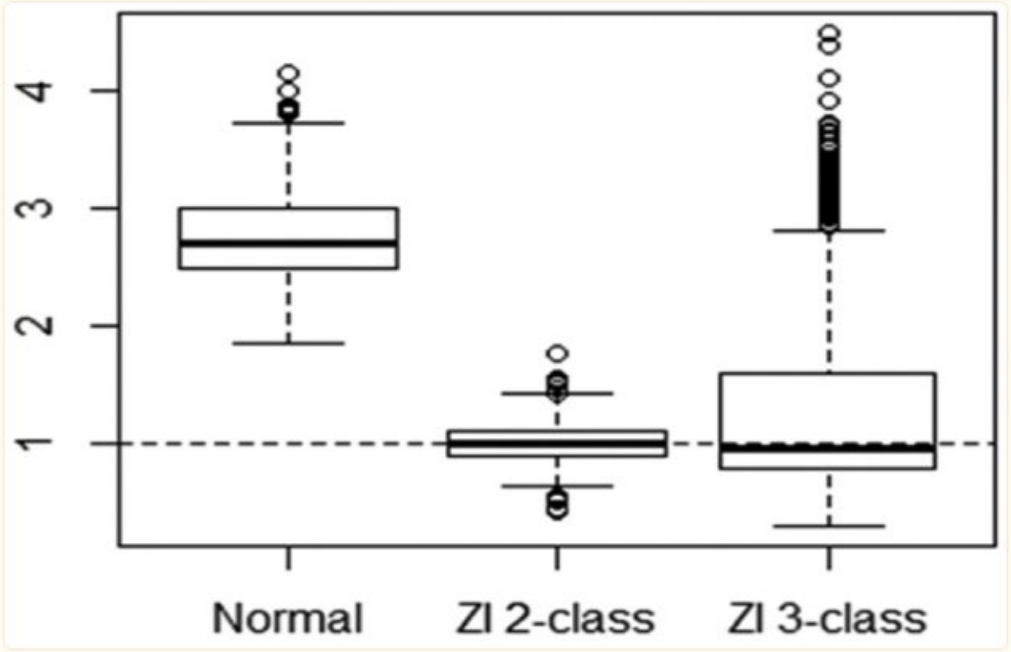


Figure 2.

Truth is ZI $K = 2$ mixture with 75% non-pathological.

Note. Side-by-side boxplots of 100 estimates of all 10 of the discrimination parameter β_1-β_{10} (true value = 1) for each of the three models. ZI = zero-inflated.

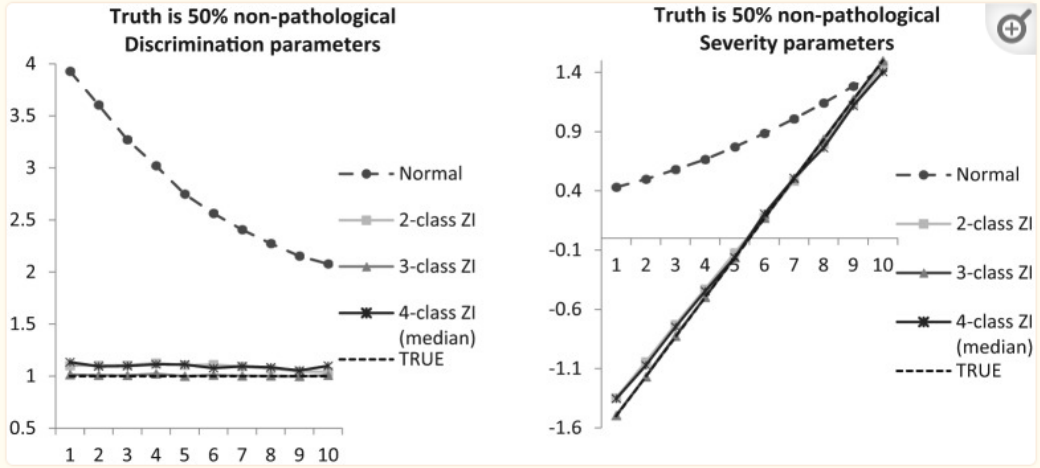


Figure 4.

Truth is ZI $K = 3$ mixture with 50% of the population non-pathological.

Note. Empirical mean (and median for the four-class ZI mixture) item parameter estimates (discrimination on left, severity on right) across 100 simulated data sets estimated with the four different models. ZI = zero-inflated.

Próxima clase

- Sesión práctica de TRI